

**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA**

**COORDENAÇÃO DO CURSO DE BACHARELADO EM
CIÊNCIA DA COMPUTAÇÃO**

JOÃO VICTOR MACHADO RANGEL

DETECÇÃO DE MISOGINIA EM MENSAGENS TEXTUAIS

TRABALHO DE CONCLUSÃO DE CURSO

RIO DE JANEIRO

2026

JOÃO VICTOR MACHADO RANGEL

DETECÇÃO DE MISOGINIA EM MENSAGENS TEXTUAIS

Trabalho de Conclusão de Curso apresentado como requisito parcial à obtenção do título de Bacharel em Ciência da Computação, da Coordenação do curso de Bacharelado em Ciência da Computação, do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca.

Orientador: Gustavo Paiva Guedes e Silva, D.Sc.¹

RIO DE JANEIRO

2026

Ficha catalográfica elaborada pela Biblioteca Central do CEFET/RJ

A ficha catalográfica contém as informações fundamentais para a identificação do TCC no sistema da biblioteca. Ela contém informações do TCC como autor, título, local, assunto, tamanho, número de páginas, tipo de trabalho científico, instituição, ano e palavras-chave.

Após a apresentação do TCC e de ter efetuado todas as correções com a anuência do(a) orientador(a), deve-se enviar a solicitação de ficha catalográfica por meio de chamado para a biblioteca. Maiores detalhes estão disponíveis no arquivo

Tutorial Ficha Catalográfica por Chamado.pdf

disponibilizado junto com os arquivos do template. O prazo de entrega da ficha é de até 3 dias úteis.

Obtida a ficha, substitua o arquivo ficha.pdf pela recebida da biblioteca para incluir na seu texto.

AGRADECIMENTOS

Agradeço ao Comitê de Ética em Pesquisa (CEP) pela análise criteriosa e pela liberação para a coleta e utilização dos dados fornecidos pelos participantes. O suporte institucional e ético foi fundamental para garantir a integridade desta pesquisa e a proteção dos direitos dos voluntários envolvidos.

Agradecimento aos participantes dos questionários aplicados. A disponibilidade e o empenho de cada colaborador em validar o repertório inicial e sugerir novas expressões foram os pilares que permitiram a construção do léxico LexMis-BR. Sem esse esforço coletivo e a riqueza das contribuições individuais, não seria possível alcançar o repertório sociolinguístico necessário para o estudo da misoginia no contexto brasileiro.

Agradeço também ao meu orientador, Gustavo Guedes, pela condução técnica e paciência ao longo de todo este processo de aprendizado.

TERMO DE APROVAÇÃO

Título: Detecção de Misoginia em Mensagens Textuais

Discente(s): João Victor Machado Rangel

Data de aprovação: _____

Banca Examinadora:

Orientador - Gustavo Paiva Guedes e Silva, D.Sc.¹

Membro Interno - Nome Membro Interno, D.Sc.¹

Membro Externo - Nome Membro Externo, D.Sc.¹

A Folha de Aprovação assinada encontra-se na Coordenação do Curso

¹Caso a titulação não seja D.Sc., utilizar a adequada (p.ex., Dr. Ing., M.Sc., Esp., entre outras)

RESUMO

João Victor Machado Rangel. **Detecção de Misoginia em Mensagens Textuais**. 2026. 41. Trabalho de Conclusão de Curso – Centro Federal de Educação Tecnológica Celso Suckow da Fonseca. Rio de Janeiro. Cidade, 2026.

Este estudo investiga a disseminação da misoginia nas redes sociais brasileiras e propõe uma abordagem fundamentada em recuperação lexical e validação humana para apoiar a sua detecção automatizada. O trabalho apresenta o desenvolvimento do LexMis-BR, um léxico expandido construído de forma colaborativa para superar a escassez de recursos linguísticos específicos para o português do Brasil. A metodologia, aprovada pelo Comitê de Ética em Pesquisa, integrou a coleta de mensagens no X com a rotulação realizada por voluntários, buscando produzir recursos alinhados ao contexto sociolinguístico nacional. A etapa de rotulação evidenciou que, embora a recuperação lexical seja útil para orientar a construção do corpus, ela se mostra insuficiente como critério de decisão final devido à ambiguidade inerente aos enunciados, o que reforça a necessidade do julgamento contextual humano na consolidação de dados confiáveis. Foram avaliados modelos supervisionados de classificação, e os resultados indicam que os recursos produzidos são relevantes para o avanço do estudo computacional da misoginia, oferecendo uma base empírica para o aprimoramento de sistemas de moderação de conteúdo no cenário brasileiro.

Palavras-chave: Misoginia; Mineração de texto; Rede social; Discurso de Ódio; Processamento de Linguagem Natural; Aprendizado de Máquina.

ABSTRACT

João Victor Machado Rangel. **Detecting Misogyny in Text Messages**. 2026. 41. Undergraduate Thesis – Federal Center of Technological Education. Rio de Janeiro. City, 2026.

This study analyzes the spread of misogyny on Brazilian social networks and proposes a method that combines word lists with human review to improve the automatic detection of such discourse. The work presents LexMis-BR, an expanded vocabulary created collaboratively to address the lack of specific databases for Brazilian Portuguese. The methodology, approved by the Research Ethics Committee, combined the collection of messages from X with rotation performed by volunteers, ensuring that the produced resources were aligned with the national sociolinguistic context. The results showed that, while word lists are useful for guiding corpus construction, they do not replace human judgment, as many utterances are inherently ambiguous and depend on context to be correctly interpreted. Finally, the performance of the evaluated supervised classification models indicates that the created resources are relevant for advancing the field, providing an empirical basis for improving content moderation systems in the Brazilian scenario.

Keywords: Misogyny; Text mining; Social network; Hate speech; Natural Language Processing; Machine Learning.

LISTA DE FIGURAS

Figura 3.1 - Ilustração dos conjuntos de dados sendo utilizados para as etapas de treino e teste gerados no procedimento de validação cruzada <i>K-Fold</i>	18
Figura 3.2 - Matriz de Confusão	19
Figura 4.1 - Diagrama exemplificando a metodologia aplicada no estudo.	21

LISTA DE TABELAS

Tabela 2.1 - Resumo do levantamento bibliográfico	10
Tabela 5.1 - Léxico final (LexMis-BR) em ordem decrescente de ocorrência.	26
Tabela 5.2 - Classificadores e grades de parâmetros dos experimentos.	30
Tabela 5.3 - Desempenho dos algoritmos em validação cruzada e <i>holdout</i>	31
Tabela 5.4 - Desempenho da <i>Regressão Logística</i> no teste <i>holdout</i>	32

LISTA DE ACRÔNIMOS

API Interface de Programação de Aplicações

BoW Bag of Words

CEP Comitê de Ética em Pesquisa

IA Inteligência Artificial

PLN Processamento de Linguagem Natural

SGD Stochastic Gradient Descent (Descida Gradiente Estocástica)

SVM Máquina de Vetores de Suporte

TCLE Termo de Consentimento Livre e Esclarecido

TF-IDF Termo Frequência - Frequência Inversa Documento

USP Universidade de São Paulo

SUMÁRIO

1	INTRODUÇÃO	1
1.1	DEFINIÇÃO DO PROBLEMA	2
1.2	OBJETIVO	3
1.3	CONSIDERAÇÃO	4
1.4	ORGANIZAÇÃO DA DISSERTAÇÃO	4
2	TRABALHOS RELACIONADOS.....	5
2.1	TAXONOMIA E VIESES EM LINGUAGEM CONFLITUOSA	5
2.2	MISOGINIA ONLINE, DINÂMICAS DE PLATAFORMA E IMPACTO PO- LÍTICO NO BRASIL	6
2.3	ESTRATÉGIAS DE COLETA E CLASSIFICAÇÃO SUPERVISIONADA	8
2.4	CONSIDERAÇÕES FINAIS.....	9
3	FUNDAMENTAÇÃO TEÓRICA	11
3.1	LÉXICO.....	11
3.2	HATEBASE.....	12
3.3	PROCESSAMENTO DE LINGUAGEM NATURAL.....	12
3.3.1	TOKENIZAÇÃO	12
3.3.2	LEMATIZAÇÃO	13
3.3.3	STOPWORDS.....	13
3.4	MINERAÇÃO DE TEXTO.....	13
3.4.1	WEB SCRAPING.....	14
3.4.1.1	Selenium	14
3.5	APRENDIZADO DE MÁQUINA	15
3.5.1	APRENDIZADO SUPERVISIONADO	15
3.5.1.1	Regressão Logística	15
3.5.1.2	Naive Bayes	16
3.5.1.3	Máquina de Vetores de Suporte (SVM)	16
3.5.1.4	Descida Gradiente Estocástica (SGD)	16
3.5.2	TERMO FREQUÊNCIA - FREQUÊNCIA INVERSA DOCUMENTO (TF- IDF)	17
3.5.3	VALIDAÇÃO CRUZADA: PROCESSO DE AVALIAÇÃO DO MODELO	17
3.6	MEDIDAS DE AVALIAÇÃO DE MODELOS DE APRENDIZADO DE MÁ- QUINA	18
3.6.1	MATRIZ DE CONFUSÃO	18
3.6.2	ACURÁCIA	19
3.6.3	PRECISÃO E REVOCACÃO.....	19

3.6.4	F-MENSURE	20
4	METODOLOGIA	21
4.1	CRIAÇÃO DO LÉXICO DE TERMOS MISÓGINOS	21
4.2	CRIAÇÃO DO CORPUS DE REDES SOCIAIS.....	22
4.3	MÉTODO DE ROTULAGEM DOS TEXTOS MISÓGINOS.....	23
4.4	AVALIAÇÃO INICIAL DE MODELOS SUPERVISIONADOS DE CLASSIFICAÇÃO.....	23
5	AVALIAÇÃO EXPERIMENTAL E RESULTADOS	25
5.1	CONSTRUÇÃO DO LÉXICO DE TERMOS MISÓGINOS	25
5.2	COLETA E CARACTERIZAÇÃO DOS TEXTOS	27
5.3	ROTULAÇÃO DOS TEXTOS E COMPOSIÇÃO DO CONJUNTO DE DADOS ROTULADOS	28
5.4	CLASSIFICAÇÃO SUPERVISIONADA DOS TEXTOS.....	29
6	CONCLUSÃO	33
7	APÊNDICE A - TERMO DE CONSENTIMENTO LIVRE E ESCLARECIDO E QUESTIONÁRIO APLICADO AOS PARTICIPANTES .	35
7.1	DADOS PESSOAIS	37
7.2	LÉXICO DE TERMOS MISÓGINOS	37
	REFERÊNCIAS	39

1 INTRODUÇÃO

A misoginia tem se disseminado de diversas maneiras pelas redes sociais nas primeiras décadas do século XXI. Ela é definida como o preconceito, hostilidade ou ódio direcionado às mulheres, e se manifesta por meio de mensagens e atitudes discriminatórias, sexistas ou violentas direcionadas ao gênero feminino [Significados 2023]. Em 2023, a psicóloga e pesquisadora da Universidade de Brasília, Valeska Zanello, propôs um projeto de lei prevendo a prática de agressão, degradação ou discriminação a mulher por preconceito ao sexo feminino, havendo a possibilidade de ser incluído junto a Lei 7.716, de 1989, da qual trata dos crimes de homofobia, transfobia e racismo [Federal 2023].

A relevância do enfrentamento à violência de gênero no Brasil ganhou um novo marco jurídico com a movimentação legislativa para a criminalização da misoginia. Conforme as recentes deliberações do Senado Federal [BRASIL 2023], a proposta de alteração na Lei nº 7.716/1989 visa incluir a misoginia, definida como a aversão, o desprezo ou o ódio contra as mulheres por sua condição de gênero, no rol de crimes resultantes de preconceito. Essa mudança não apenas tipifica condutas de discriminação e intolerância, mas também estabelece penas mais severas para crimes cometidos em ambientes virtuais, reconhecendo o potencial nocivo e a rápida propagação do ódio digital. Ao elevar a misoginia ao status de crime, o Estado brasileiro reafirma o compromisso com a proteção da dignidade da mulher, oferecendo o suporte legal necessário para que mecanismos de detecção e punição de discursos abusivos possam operar de forma mais eficaz e institucionalizada.

O fenômeno da misoginia digital atual encontra uma de suas expressões mais articuladas no movimento *Red Pill*, uma vertente do masculinismo que se popularizou no Brasil a partir de transformações tecnológicas e sociopolíticas da última década. Conforme analisa [Ferreira 2025], essa ideologia utiliza a metáfora cinematográfica da “pílula vermelha” para alegar a revelação de uma suposta realidade oculta, na qual os homens seriam vítimas de um sistema social dominado por interesses femininos. No contexto brasileiro, o movimento foi importado do mundo anglo-saxão e adaptado por influenciadores digitais, florescendo em nichos como o “Redcast”, onde discursos de resistência ao feminismo são mesclados a uma lógica neoliberal de subjetivação e autoajuda masculina.

A disseminação dessas narrativas em plataformas como o YouTube não representa apenas um conflito de opiniões, mas a consolidação de comunidades que dialogam diretamente com o pensamento da direita radical e promovem uma visão essencialista e hierárquica das relações de gênero. [Ferreira 2025] destaca que essa “visualização de machismos virtuais” é impulsionada por algoritmos que favorecem o engajamento através do conflito, criando ambientes onde a desumanização da mulher e a reiteração de estereótipos patriarcais são validadas como formas de “despertar” para o homem moderno. Portanto, compreender a estrutura desses discursos é fundamental para o desenvolvimento de ferramentas de processamento de linguagem natural que visem identificar e mitigar a

propagação de conteúdos misóginos em redes de alta capilaridade.

Jornais e portais de notícia alertam que o discurso de ódio está se disseminando nas redes sociais. Segundo o jornal da USP [Fogaça 2023], a propagação de discursos machistas ganha força na internet e traz impactos reais para as mulheres, alerta o psicólogo e mestrando da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo (FFCLRP), André Villela de Souza Lima Santos. Dessa maneira, podemos estudar a misoginia em redes sociais específicas, nesse caso, o X (antigo Twitter).

O Twitter é um serviço de microblogue, atualmente chamado de X, em que as pessoas e empresas podem se comunicar por meio de mensagens curtas. Segundo a rede, em sua página de perguntas frequentes [X 2026], essas mensagens são publicadas e compartilhadas pelos usuários em seus perfis, podendo ser encontradas por meio de busca na rede (manual ou com uso de plataformas mineradoras). Em meio a polêmicas quanto ao conteúdo dos posts realizados pelos usuários, e a uma discussão pública sobre os papéis das plataformas como reguladoras desse tipo de conteúdo, em 2023, a rede social definiu regras para combater o abuso, a violência e o discurso de ódio. A “conduta de propagação de ódio” define que não é permitido promover violência, atacar diretamente ou ameaçar outras pessoas com base no sexo ou na identidade de gênero.

1.1 DEFINIÇÃO DO PROBLEMA

A identificação de condutas abusivas em ambientes digitais é balizada por políticas de uso que tentam delimitar as fronteiras entre a liberdade de expressão e a violação de direitos humanos. No caso da plataforma X, a política de conduta odiosa proíbe explicitamente ataques diretos, ameaças ou o incentivo à violência contra indivíduos com base em categorias protegidas, nas quais o gênero e a identidade de gênero ocupam posição central [X Corp. 2024]. A plataforma define como infração o uso de epítetos de ódio, tropos desumanizantes e imagens que visem degradar ou reforçar estereótipos prejudiciais contra mulheres.

Para aplicar essas regras de maneira eficaz, seria necessário realizar uma revisão manual extensa de cada mensagem compartilhada na plataforma. Hoje, este tipo de ferramenta é majoritariamente acionada com a ação individual dos usuários, que podem denunciar determinado conteúdo para análise pelo Twitter. Em um estudo conduzido por [MacAvaney et al. 2019], foi observado que o uso de ferramentas automatizadas baseadas em Processamento de Linguagem Natural (PLN) pode agilizar o processo de curadoria de conteúdo. Isso abriria a possibilidade para o Twitter evitar a disseminação de mensagens misóginas no momento de sua publicação, impedindo assim a propagação desses conteúdos prejudiciais na rede social.

Uma limitação da classificação automática de textos de caráter misógino é a ausência de alguns léxicos para discurso de ódio contra a mulher no idioma português

brasileiro. A ferramenta *Hatebase*, por exemplo, apresenta vocabulário multilíngue, mantido por funcionários e voluntários em mais de 90 idiomas e mais de 200 países. Para a construção do [Hatebase 2024], foi desenvolvido o *Hatebrain*, uma engenharia de processamento de linguagem natural que realiza análises linguísticas em conversas públicas para estimar a probabilidade de conteúdo com discurso de ódio. Todos os dados estão disponíveis para consulta por meio do seu site ou sua interface de programação de aplicativos, em inglês, API.

Embora a plataforma Hatebase seja uma das principais referências globais para o monitoramento de discurso de ódio, sua cobertura para a língua portuguesa ainda é limitada, contando com apenas 11 termos catalogados até o período desta pesquisa. Além do baixo volume, observa-se que parte desses termos reflete variantes do português de Portugal, o que compromete a eficácia da detecção no cenário brasileiro. Essa lacuna quantitativa e qualitativa justifica a necessidade de criação do LexMis-BR, um recurso especializado que visa expandir e adaptar o léxico às nuances sociolinguísticas do Brasil.

1.2 OBJETIVO

Apresentada a definição do problema na seção anterior, o objetivo central da pesquisa é desenvolver um método de identificação do discurso misógino em mensagens de redes sociais. O intuito do estudo está em produções textuais, revisando conceitos e literatura pertinente às metodologias de classificação computacional de manifestações de ódio. Prioriza-se, especificamente, o fenômeno da misoginia no contexto do português brasileiro. Com o intuito de atingir o objetivo macro, definiram-se os próximos passos detalhados:

- Construção e validação do recurso LexMis-BR, um léxico expandido de termos misóginos orientado por participantes.
- Criação de uma base de dados de textos, produzidos por meio da extração de mensagens em redes sociais.
- Rotulagem dos textos a partir do julgamento humano para as classes 'Considero misógina', 'Não considero misógina' ou 'Não sei definir'.
- Aplicação de modelos de classificação supervisionada ao conjunto de dados rotulados, comparando o desempenho de algoritmos como *Regressão Logística*, *SGDClassifier*, *LinearSVC* e *Naive Bayes*.

1.3 CONSIDERAÇÃO

Em conformidade com as normas éticas para pesquisas envolvendo seres humanos, os procedimentos relativos à construção do léxico e à rotulagem das mensagens coletadas foram submetidos ao Comitê de Ética em Pesquisa (CEP) do Ministério da Saúde. O projeto foi devidamente aprovado sob o protocolo número 75789023.0.0000.5289, assegurando o cumprimento das diretrizes de proteção aos voluntários e o tratamento adequado das informações coletadas. Como desdobramento acadêmico da pesquisa, destaca-se a publicação do artigo científico intitulado “Detecção de Misoginia em Redes Sociais”, no XV Brazilian Workshop on Social Network Analysis and Mining (BraSNAM 2026), evento integrante do XLVI Congresso da Sociedade Brasileira de Computação (SBC).

- RANGEL, J.; FEITOSA, A.; RIOS, A.; FERRARI, L.; JUNIOR, F.; BELLOZE, K. T.; OGASAWARA, E.; GUEDES, G. P. . Detecção de Misoginia em Redes Sociais. In: XV Brazilian Workshop on Social Network Analysis and Mining (BraSNAM), 2026, Maceió. Anais do 46º Congresso da Sociedade Brasileira de Computação (SBC), 2026. Gramado: SBC, 2026.

1.4 ORGANIZAÇÃO DA DISSERTAÇÃO

Este Trabalho de Conclusão de Curso está estruturado em cinco capítulos que detalham o desenvolvimento e a avaliação da metodologia proposta. O primeiro capítulo, esta Introdução, contextualiza a relevância do tema frente ao cenário jurídico e social brasileiro e define os objetivos da pesquisa. Na sequência, o segundo capítulo apresenta os Trabalhos Relacionados, revisando o estado da arte na detecção de misoginia a partir de buscas em bases como *Scopus* e *ACM*. O terceiro capítulo dedica-se a Fundamentação Teórica, estabelecendo as bases conceituais de Processamento de Linguagem Natural e Aprendizado de Máquina necessárias para a compreensão técnica do sistema.

O quarto capítulo descreve a Metodologia, detalhando desde a criação do recurso *LexMis-BR* e a coleta de dados em redes sociais até os processos de rotulação humana e pré-processamento de texto. O quinto capítulo é dedicado à apresentação e discussão dos Resultados, avaliando o desempenho de classificadores como *Regressão Logística*, *Naive Bayes*, *SGDClassifier*, *LinearSVC* por meio de métricas de F1-score e matrizes de confusão. Por fim, o sexto capítulo encerra o trabalho com as Considerações Finais, sintetizando as contribuições acadêmicas, as limitações do estudo e as perspectivas para investigações futuras na área de segurança digital.

2 TRABALHOS RELACIONADOS

A detecção automática de discursos de ódio e misoginia é um campo consolidado que enfrenta desafios crescentes quanto à curadoria de dados e adaptação cultural, especialmente no português do Brasil. Para fundamentar este estudo, realizou-se uma busca sistemática via Portal de Periódicos CAPES, utilizando as bases *Scopus* (onde obteve-se 1 resultado) e *ACM Digital Library* (onde obtiveram-se 6 resultados), os demais trabalhos foram encontrados através da técnica de snowballing. A estratégia de busca utilizada foi: `Misogyny AND ( "text mining" OR "machine learning" ) AND portuguese`. A partir desse levantamento, selecionou-se um conjunto de trabalhos que serviu de base teórica e metodológica para esta pesquisa: os estudos de [Balayn et al. 2021] e [Koch et al. 2025], que abordam taxonomias e impactos políticos, o estudo temporal de [Martins et al. 2025] sobre comunidades masculinas em plataformas de vídeo, a investigação a respeito da construção de bases de dados nativas, além das propostas práticas de classificação supervisionada em língua portuguesa desenvolvidas por [Silva 2023.], [Santos 2024.] e de [Plath et al. 2022]. Nas subseções seguintes, esses trabalhos são detalhados e comparados as abordagens adotadas nesta pesquisa.

A partir desse levantamento, selecionou-se um conjunto de trabalhos que serviu de base teórica e metodológica para esta pesquisa: os estudos de [Balayn et al. 2021] e [Koch et al. 2025], que abordam taxonomias e impactos políticos; o estudo temporal de [Martins et al. 2025] sobre comunidades masculinas em plataformas de vídeo; a investigação de [?] a respeito da construção de bases de dados nativas; além das propostas práticas de classificação supervisionada em língua portuguesa desenvolvidas por [Silva 2023.] e [Santos 2024.]. Nas subseções seguintes, esses trabalhos são detalhados e comparados as abordagens adotadas nesta pesquisa.

2.1 TAXONOMIA E VIESES EM LINGUAGEM CONFLITUOSA

A compreensão do que constitui o discurso abusivo é o primeiro desafio metodológico para a automação de sistemas de detecção. [Balayn et al. 2021] realizam um levantamento sistemático que evidencia uma desconexão crítica entre as definições teóricas da psicologia e as implementações práticas em Ciência da Computação. Os autores argumentam que a literatura técnica frequentemente falha em capturar a natureza multidimensional da ofensa, resultando em sistemas que tratam o fenômeno de forma puramente léxica, ignorando variáveis como intenção, comportamento, alvo e efeito.

Para mitigar essa confusão terminológica, [Balayn et al. 2021] propõem o termo *Online Conflictual Language* (OCL) como uma categoria guarda-chuva que engloba o discurso de ódio, o *cyberbullying*, a agressão e a profanidade. Segundo a taxonomia proposta, a misoginia é classificada como um subtipo de sexismo, inserido no grupo das lingua-

gens ofensivas, caracterizadas por focar em características intrínsecas de um indivíduo ou grupo. Os autores sugerem que um modelo robusto deve considerar sete propriedades binárias: intenção de ferir, tipo de comportamento, foco específico (ex: gênero), emoção do autor, tipo de linguagem, alvo e efeito sobre o leitor.

Além da taxonomia, o estudo identifica três categorias principais de vieses que comprometem a eficácia dos classificadores automáticos:

- **Viés de Representação:** Ocorre quando os conjuntos de dados de treinamento são compostos majoritariamente por termos ofensivos explícitos, falhando em detectar formas sutis ou “codificadas” de ódio, o que torna o sistema ineficaz em cenários reais.
- **Viés de Rotulação:** Origina-se da falta de clareza nas instruções dadas aos anotadores humanos. Os autores observam que, sem definições precisas de categorias como “ódio” ou “ofensa”, os anotadores projetam suas próprias subjetividades, o que resulta em baixos índices de concordância inter-anotadores (como o *Kappa de Cohen*).
- **Viés de Contexto:** Os modelos tendem a ignorar o contexto subjetivo do alvo e do observador. O estudo ressalta que a percepção de uma mensagem depende de fatores externos, como a origem étnica ou o gênero de quem lê, o que reforça a necessidade de curadoria manual e validação humana em vez de uma dependência estrita de gatilhos lexicais.

Essas constatações fundamentam a escolha metodológica da presente pesquisa ao privilegiar a validação humana após a recuperação léxica, garantindo que o conjunto consolidado reflita ofensas reais e não apenas o uso neutro de termos isolados.

2.2 MISOGINIA ONLINE, DINÂMICAS DE PLATAFORMA E IMPACTO POLÍTICO NO BRASIL

No cenário brasileiro, a misoginia online adquire contornos específicos e intensificados durante períodos de polarização política. [Koch et al. 2025] investigaram esse fenômeno durante as eleições gerais de 2022, analisando um volume massivo de 10 milhões de *tweets* direcionados a candidatas brasileiras. O estudo destaca que, embora o ambiente digital ofereça oportunidades sem precedentes para a participação política feminina, ele também se tornou um terreno fértil para a violência de gênero facilitada pela tecnologia, atuando como um mecanismo de controle social que pune mulheres que desafiam normas tradicionais de poder. Utilizando classificadores de aprendizado de máquina treinados especificamente para identificar a natureza da misoginia em língua portuguesa, os auto-

res revelaram que a exposição ao ódio não é uniforme entre as candidatas. A pesquisa identificou perfis de maior vulnerabilidade por meio de uma análise de heterogeneidade:

- **Ideologia Política:** Candidatas de espectro político à esquerda e extrema-esquerda receberam um volume significativamente maior de ataques misóginos em comparação com candidatas de centro ou de direita.
- **Fator Geracional:** Mulheres jovens (abaixo de 30 anos) foram alvos mais frequentes de agressões, com o volume de menções misóginas diminuindo progressivamente conforme o aumento da idade da candidata.
- **Hierarquia e Visibilidade:** Candidatas com maior número de seguidores e alta atividade na rede social atraíram mais ataques, porém, mulheres que concorriam a cargos de menor hierarquia (como deputadas estaduais) enfrentaram ataques mais persistentes, possivelmente devido à menor estrutura de suporte profissional e partidário para gestão de crises online.

O estudo de [Koch et al. 2025] é pioneiro ao quantificar o impacto comportamental dessa violência através do “efeito de dissuasão”. Os resultados demonstram que um aumento nas agressões misóginas em uma determinada semana está estatisticamente correlacionado à diminuição da atividade comunicativa da candidata na semana seguinte. Essa constatação evidencia como a misoginia online opera como uma ferramenta de silenciamento sistemático no debate público, ameaçando a representação política feminina ao expulsar ou desestimular vozes de mulheres no discurso político.

Aprofundando a investigação sobre os mecanismos de propagação desse ecossistema fora das redes baseadas estritamente em microtextos, [Martins et al. 2025] realizaram um estudo de caso focado na comunidade Red Pill dentro do YouTube brasileiro. Analisando um corpus expressivo de 18.034 vídeos e mais de 2,2 milhões de comentários extraídos de 28 canais ativos entre 2024 e 2025, os autores mapearam os padrões de engajamento e as estratégias discursivas empregadas pelos criadores de conteúdo para expandir narrativas extremistas.

Os achados de [Martins et al. 2025] revelam uma importante dualidade e dissimulação nas estratégias de publicação: enquanto os metadados dos vídeos (títulos e descrições) mantêm, em mais de 77% dos casos, uma abordagem de sentimento neutro e enigmático para maximizar o alcance e contornar filtros automáticos de moderação, os comentários dos usuários apresentam uma alta incidência de negatividade (53%), toxicidade elevada e misoginia explícita. Mediante a modelagem com o algoritmo *BERTopic*, a pesquisa identificou que as narrativas centrais desse ecossistema se ancoram fortemente na oposição a pautas feministas, na exaltação da família tradicional e em discursos voltados ao desenvolvimento e performance individual masculina.

Essas constatações, tanto no Twitter quanto no YouTube, reforçam de maneira complementar a necessidade de modelos de detecção robustos para o português brasileiro, como o proposto nesta pesquisa. Enquanto as análises literárias evidenciam que gatilhos lexicais isolados ou ferramentas automatizadas sem ajustes de limiares contextuais falham em capturar as nuances veladas e os termos internos das subculturas de comunidades masculinistas, este trabalho privilegia a validação humana após a recuperação léxica para blindar o conjunto consolidado contra ambiguidades ou usos neutros da língua.

2.3 ESTRATÉGIAS DE COLETA E CLASSIFICAÇÃO SUPERVISIONADA

Alguns estudos, como o elaborado por [Santos 2024.], conduziram uma investigação acerca de mensagens com conteúdo homofóbico em língua portuguesa, no contexto da plataforma Twitter, já com dados do “Hatebase” em português. A pesquisa teve seu início com a análise e síntese de termos relevantes, utilizando técnicas de mineração de texto, particularmente o método “Bag of Words” (BoW), o qual cria um vocabulário de todas as palavras únicas que ocorrem em todos os documentos do conjunto de treinamento. A ideia principal do BoW é transformar um texto em um conjunto de palavras, sem levar em conta a ordem em que aparecem ou a estrutura gramatical. No trabalho de Santos, durante a etapa de coleta de dados, foi empregada a API do Twitter para extrair um total de 2.597 mensagens que eram respostas a postagens feitas pelo ex-deputado federal Jean Wyllys em sua rede social. Dentro deste conjunto de mensagens, identificou-se a participação de 827 usuários únicos que utilizaram um ou mais termos previamente catalogados no Hatebase. Entre os termos mais frequentemente empregados nas respostas, destacam-se palavras como “viado” e “bicha”, além da presença de termos menos recorrentes, como “biba” e “gay”. Esta análise revela a aplicação eficaz de técnicas de análise textual e léxicos em um tema de grande relevância na sociedade, possibilitando a identificação de casos de homofobia nas redes sociais e promovendo a criação de bases para futuras investigações neste domínio.

Recentemente, em 2023, [Silva 2023.] elaborou uma monografia relacionada ao mesmo tema abordado no presente estudo: o discurso de ódio contra a mulher no Twitter. O objetivo foi constituir um conjunto de dados de termos voltados para a problemática da violência contra a mulher. Contudo, a coleta de dados para a construção do dataset foi baseada apenas em bibliografias a respeito do tema, diferentemente do que ocorre neste trabalho. A intenção foi produzir conteúdo mais alinhado ao percebido pelos usuários e eliminar falsos positivos devidos à variabilidade semântica nas palavras encontradas. Por isso, a categorização aqui presente foi filtrada a partir da percepção dos usuários, em questionário aplicado e encontrado no Apêndice A desta monografia. Faz-se, porém, importante salientar que o presente trabalho pretende colaborar, em vez de discordar, com as conclusões das autoras, expandindo-as para torná-las mais adequadas ao contexto de

uso brasileiro, especialmente em meios digitais. É sabido que qualquer pesquisa depende da confiabilidade e representatividade da amostra e, portanto, consideramos que um novo conjunto de participantes adicionaria visões relevantes ao exíguo conjunto de dados sobre discurso de ódio misógino nas redes sociais disponível na Hatebase.

Visando mitigar de forma robusta essa escassez de recursos públicos voltados ao cenário nacional, [Plath et al. 2022] descreveu o processo de desenvolvimento e especificação da base MINA-BR, um repositório contendo 6.002 comentários coletados de maneira equilibrada entre as plataformas Twitter e YouTube. O método de extração baseou-se em termos identificados por uma pesquisa em formulário online com estudantes universitários, resultando em descritores específicos como "feminazi" e "abortista". Para o processo de classificação, os autores estruturaram uma plataforma web onde voluntários avaliaram os textos em duas fases consecutivas (verificação de ofensividade seguida por categorização do ódio direcionado à mulher) sob uma escala *Likert* de certeza.

2.4 CONSIDERAÇÕES FINAIS

Com base nos estudos discutidos, identifica-se uma oportunidade de pesquisa fundamental: a necessidade de desenvolver instrumentos que superem a visão puramente terminológica da ofensa, uma vez que o vocabulário isolado é insuficiente para confirmar a misoginia. O presente estudo atua justamente nessa interseção, propondo uma metodologia que une expansão lexical orientada por participantes, coleta de mensagens em rede social, rotulação humana e modelagem computacional para produzir um léxico de termos misóginos expandido (*LexMis-BR*), oferecendo um suporte empírico necessário para o aprimoramento de futuros sistemas de detecção automática no Brasil.

Cabe ressaltar que, embora a literatura aponte a relevância de investigar as distorções em sistemas preditivos, este trabalho não concentra seus esforços na análise detalhada de vieses técnicos, de anotação ou de contexto, conforme mapeado por [Balayn et al. 2021]. O escopo desta pesquisa debruça-se, estritamente, na viabilidade prática de estruturação do recurso lexical colaborativo e na avaliação inicial do desempenho de classificadores supervisionados para o cenário nacional.

A tabela 2.1 sintetiza as principais contribuições, metodologias e métricas de desempenho dos estudos analisados, estabelecendo um paralelo direto entre a literatura revisada e a abordagem proposta nesta pesquisa.

Autor (Ano)	Domínio	Técnica Principal	Base de Dados	Diferencial
Balayn et al. (2021)	Geral (OCL)	Formulário / Taxonomia	Diversas	Foco em vieses técnicos e psicológicos.
Koch et al. (2025)	Misoginia Política	ML / Análise Longitudinal	Twitter	Análise do silenciamento de candidatas brasileiras.
Martins et al. (2025)	Misoginia (Red Pill)	PLN / BERT	YouTube	Contraste discursivo entre vídeos e comentários.
Silva (2023).	Misoginia	SGDClassifier / Naive Bayes / Elastic Stack	Twitter	Uso de ferramentas de busca em tempo real.
Santos (2024)	Homofobia	Random Forest / KNN	Twitter	Expansão de léxico homofóbico via contribuição humana.
Plath et al. (2022)	Misoginia	LinearSVC/ BERT / Random Forest / NB	Twitter / YouTube	Construção da base MINA-BR via contribuição humana.
Este Trabalho	Misoginia	Regressão Logística / SGDClassifier/ Naive Bayes / LinearSVC	Twitter	Expansão de léxico de termos misóginos via contribuição humana (LexMis-BR).

Tabela 2.1: Resumo do levantamento bibliográfico

3 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos e as bases tecnológicas utilizadas para o desenvolvimento desta pesquisa. Inicialmente, abordam-se as definições de Léxico e o funcionamento da plataforma Hatebase, que servem como base para a identificação do discurso de ódio. Em seguida, detalham-se os processos de Processamento de Linguagem Natural (PLN), com foco nas técnicas de tokenização, lematização e remoção de stopwords utilizadas na biblioteca SpaCy.

Também são apresentados os conceitos de Mineração de Texto e a utilização do Selenium como ferramenta de automação para a coleta de dados via Web Scraping. Sendo explorados também os princípios do Aprendizado de Máquina e, especificamente, do Aprendizado Supervisionado, que formam a base para a construção de modelos preditivos. Em seguida, detalham-se os modelos de classificação selecionados para o estudo, a Regressão Logística, o Naive Bayes, Máquina de Vetores de Suporte (SVM) e Descida Gradiente Estocástica (SGD).

Além da modelagem, este capítulo aborda a técnica de extração de características Termo Frequência – Frequência Inversa de Documento (TF-IDF), essencial para a representação numérica de textos, e o método de Validação Cruzada, utilizado para garantir a robustez estatística dos experimentos. Por fim, são discutidas as Medidas de Avaliação de Modelos de Aprendizado de Máquina, incluindo a matriz de confusão e as métricas de acurácia, precisão, revocação e F-Measure, medidas fundamentais para a análise crítica do desempenho dos classificadores desenvolvidos.

3.1 LÉXICO

De acordo com [Biderman 1996], o léxico é um componente essencial da gramática e pode ser definido como o conjunto total de palavras pertencentes a uma língua, a um dialeto ou até mesmo ao repertório de um falante específico. Ele atua como um repositório de termos utilizados para a comunicação.

É comum a associação do termo léxico a conceitos mais restritos, como dicionário ou vocabulário, porém, na linguística, sua compreensão é mais abrangente. Esse conceito permite analisar o idioma sob diversas perspectivas, como a evolução das palavras ao longo do tempo ou as variações que ocorrem em diferentes regiões. Um exemplo claro dessa diversidade é a diferença entre o português do Brasil e o de Portugal; embora se trate da mesma língua, as variações lexicais demonstram como a cultura e a história de cada país influenciam a forma como o idioma é utilizado.

Considerando o escopo deste trabalho, o conceito estende-se para a definição de léxico especializado ou de especialidade. Sob a perspectiva da terminologia e das linguagens de domínio, o léxico pode ser delimitado como o subconjunto de unidades linguísticas e le-

xicais empregadas de forma recorrente dentro de um campo de conhecimento ou contexto social específico [Carneiro 2012]. Dessa forma, para esta investigação, o termo assume o papel de um inventário estruturado de palavras e expressões próprias do domínio da misoginia e do discurso de ódio no cenário digital.

3.2 HATEBASE

O *Hatebase* é um repositório multilíngue especializado na catalogação de termos e expressões que caracterizam o discurso de ódio, descrito em [Hatebase 2024]. A plataforma foi desenvolvida a partir do “Hatebrain”, um sistema de processamento de linguagem natural que realiza análises linguísticas em diálogos públicos para estimar a probabilidade de um conteúdo ofensivo.

Atualmente, o *Hatebase* abrange dados de mais de 90 idiomas e 176 países, sendo mantido por uma rede de colaboradores e voluntários. O acesso a esses dados pode ser realizado pelo site online, bem como por meio de uma API [Hatebase 2024]. No entanto, um desafio identificado para o contexto desta pesquisa é a escassez de léxicos abrangentes para o português brasileiro na base de dados, constam apenas 11 termos na língua portuguesa no período pesquisado, dos quais alguns são recorrentes em outros países, como Portugal.

3.3 PROCESSAMENTO DE LINGUAGEM NATURAL

O Processamento de Linguagem Natural (PLN) é uma abordagem computacional baseada em teorias e tecnologias voltadas para a análise de textos. Buscando capacitar sistemas computacionais a compreender e processar a linguagem humana, permitindo a extração de significados e a identificação de padrões em grandes volumes de dados textuais, conforme relatado em [Fanni et al. 2023].

No âmbito deste trabalho, o PLN é a ferramenta que permite transformar mensagens brutas de redes sociais em dados estruturados, possibilitando que algoritmos identifiquem padrões de discurso de ódio.

3.3.1 Tokenização

A tokenização é definida como a tarefa de segmentar uma cadeia de caracteres em unidades semânticas discretas, denominadas *tokens*. Este processo é formado pela etapa preliminar e obrigatória em sistemas de Processamento de Linguagem Natural (PLN), transformando texto bruto em uma sequência de elementos que podem ser processados por algoritmos estatísticos.

A complexidade desta etapa de pré processamento consiste na correta identificação dos limites de cada unidade, especialmente em redes sociais, onde a presença de

pontuações excessivas, *emojis* e abreviações desafia as regras sintáticas tradicionais. Conforme apontado por [Manning e Schütze 1999], a precisão na tokenização é determinante para o desempenho de modelos de detecção de discurso de ódio, pois uma segmentação incorreta pode resultar na perda de contexto ou na má interpretação de termos ofensivos.

3.3.2 Lematização

A lematização é o processo de agrupar as formas flexionadas de uma palavra para que possam ser identificadas como um elemento único, denominado lema ou forma de vocabulário. Conceitualmente, trata-se de uma técnica algorítmica voltada à identificação do lema de uma palavra, priorizando a raiz morfológica real em vez de apenas o radical bruto. O processo fundamenta-se no significado pretendido que a palavra busca transmitir no contexto em que está inserida, conforme relatado em [Khyani et al. 2021].

No desenvolvimento deste estudo, a aplicação dessa técnica é essencial para o tratamento de dados, pois garante que variações de termos misóginos sejam agrupadas corretamente sob uma mesma base semântica. Ao priorizar a análise do contexto e da morfologia, a lematização permite que o modelo de classificação atinja uma precisão superior ao lidar com as nuances da linguagem natural. Dessa forma, evita-se que palavras com o mesmo sentido gramatical sejam tratadas como unidades distintas, o que poderia comprometer o desempenho final dos algoritmos.

3.3.3 Stopwords

Com base na pesquisa de [Sarica e Luo 2021], as Stopwords são definidas como componentes de dados que, apesar de aparecerem com elevada frequência em diversos documentos ou partes de um texto, possuem baixo valor informativo. Esses termos geralmente consistem em palavras funcionais, como artigos e preposições, que auxiliam na estrutura gramatical, mas carregam pouca ou nenhuma informação específica sobre o conteúdo temático ao qual pertencem.

A remoção desses termos constitui uma etapa padrão no pré-processamento de tarefas de Processamento de Linguagem Natural (PLN). O objetivo principal dessa limpeza é aumentar a relação sinal-ruído no texto estruturado, permitindo que o modelo foque apenas nos termos que possuem relevância semântica. Ao eliminar esse “ruído”, melhora-se a significância estatística das palavras que realmente importam para a análise, o que resulta em uma representação mais fiel dos dados e em um melhor desempenho dos algoritmos de classificação.

3.4 MINERAÇÃO DE TEXTO

A Mineração de Textos é uma vertente multidisciplinar da mineração de dados que une inteligência artificial, aprendizado de máquina e estatística para extrair conhecimento

de grandes volumes de textos não estruturados, relatado em [Morais e Ambrósio 2007]. Enquanto a abordagem tradicional foca em bancos de dados estruturados, essa especialidade utiliza algoritmos para processar documentos e mensagens informais, identificando padrões ocultos que seriam inviáveis de ser mapeados manualmente.

Segundo a literatura, o campo opera como um processo iterativo voltado a descobrir padrões válidos, inéditos e úteis. Esse fluxo envolve a preparação dos dados textuais, a busca algorítmica e a avaliação do conhecimento extraído, exigindo que os resultados possuam certeza estatística e linguagem compreensível. Na prática, a escolha, configuração e execução repetida dos algoritmos são direcionadas estritamente para atender aos objetivos definidos para o problema estudado.

3.4.1 Web Scraping

De acordo com [Khder 2021], o Web Scraping é caracterizado como uma estratégia essencial para a obtenção de dados diretamente da internet. Essa técnica torna-se especialmente relevante em cenários onde as Interfaces de Programação de Aplicações (APIs) são inexistentes, apresentam limitações técnicas ou possuem custos elevados para o acesso.

Embora as APIs sejam ferramentas projetadas para facilitar a comunicação entre servidores e fornecer dados de maneira organizada, elas frequentemente impõem restrições por não serem gratuitas ou quanto ao volume e ao tipo de informação disponibilizada. Nesses casos, o Web Scraping permite contornar tais barreiras ao realizar a coleta automatizada de informações diretamente do código-fonte das páginas web, possibilitando o acesso a conjuntos de dados mais amplos e diversificados para análise.

3.4.1.1 Selenium

O Selenium é uma ferramenta de código aberto que utiliza uma coleção de APIs, denominada *WebDriver*, para a automação de navegadores *web*. Originalmente concebido para a automação de testes de aplicações, o Selenium permite reduzir o tempo gasto em processos repetitivos ao simular interações humanas em interfaces digitais, segundo [Yuan et al. 2023].

No desenvolvimento deste estudo, a ferramenta é empregada para implementar operações de navegação simulada e automatizada, estabelecendo a comunicação necessária para a extração de dados em tempo real. Essa funcionalidade permite que o sistema interaja diretamente com a interface do usuário no navegador, contornando a necessidade de acesso a APIs oficiais de plataformas como o Twitter (X).

3.5 APRENDIZADO DE MÁQUINA

Segundo [Monard e Baranauskas 2003], o Aprendizado de Máquina é uma subdivisão da Inteligência Artificial (IA) voltada ao desenvolvimento de técnicas computacionais que permitem a construção de sistemas capazes de adquirir conhecimento de maneira automática. Um sistema de aprendizado é caracterizado como um programa de computador que toma decisões fundamentadas em experiências acumuladas por meio da resolução bem-sucedida de problemas anteriores.

Esses sistemas possuem características específicas que permitem sua classificação de acordo com a linguagem de descrição, o modo, o paradigma e a forma de aprendizado empregada. No contexto deste estudo, tais conceitos são fundamentais para a implementação de modelos que possam identificar padrões de discurso de ódio de forma autônoma, utilizando a base de dados rotulada para "aprender" a distinguir mensagens misóginas de conteúdos neutros.

3.5.1 Aprendizado Supervisionado

O aprendizado supervisionado é definido como uma das metodologias mais difundidas no campo do aprendizado de máquina, caracterizando-se pela capacidade de utilizar dados de treinamento previamente anotados. Nesse processo, os algoritmos utilizam rótulos, conhecidos como etiquetas de classe (*class labels*), para aprender a mapear entradas em saídas específicas durante o processo de classificação. Conforme descrito por [Nasteski 2017].

O objetivo principal é construir um modelo que represente adequadamente um conjunto de dados selecionado, permitindo a resolução de problemas por meio dessa representação. No aprendizado supervisionado, o sistema passa por uma etapa de treinamento utilizando exemplos previamente corrigidos e rotulados. Esse procedimento permite que, após a finalização dessa fase, o modelo seja capaz de prever os rótulos de novos dados que não foram apresentados durante o processo de treinamento.

3.5.1.1 Regressão Logística

O termo regressão é considerado, de certa forma, um equívoco, uma vez que se trata geralmente de um método de classificação que utiliza uma função logística para prever uma variável dependente dicotômica (alvo) [Rashidi et al. 2019]. Uma variação desse método, a regressão logística multinomial, também pode ser utilizada para classificar mais de dois alvos. Na abordagem binária, a função gera um valor de 0 ou 1, representando os casos negativo (0) e positivo (1). Isso é realizado através do cálculo de uma probabilidade de razão de chances (*odds ratio*) para atribuir um valor como positivo ou negativo, baseando-se nas relações entre as variáveis de entrada independentes (*features*) e as variáveis dependentes (alvo).

O uso do método de regressão logística pode tornar-se limitante caso haja um

grande número de características ou variáveis presentes, ou se as variáveis estiverem altamente correlacionadas. Adicionalmente, esta abordagem assume que a relação entre as variáveis independentes e as variáveis dependentes é uniforme, o que pode restringir o desempenho do modelo.

3.5.1.2 Naive Bayes

Os classificadores Naive Bayes utilizam uma abordagem probabilística fundamentada no teorema de Bayes. Conforme [Rashidi et al. 2019], esse classificador é fundamental na lógica Bayesiana, operando sob a premissa ingênua de que todas as características analisadas em um conjunto de dados são totalmente independentes entre si. Essa simplificação teórica assume que a presença ou ausência de um atributo específico não possui relação direta com a existência de qualquer outra variável dentro do modelo.

Apesar da suposição de independência ser possivelmente interpretada como uma limitação do método, na prática, os classificadores Naive Bayes demonstram utilidade ao apresentarem resultados satisfatórios em diversas aplicações. Embora sua eficácia seja notavelmente relevante em tarefas de classificação com menor complexidade computacional, o Naive Bayes demonstra robustez como modelo de referência em problemas de (PLN), servindo como uma base comparativa essencial para algoritmos mais complexos.

3.5.1.3 Máquina de Vetores de Suporte (SVM)

Conforme [Rashidi et al. 2019], a Máquina de Vetores de Suporte (também denominada de Linear SVC) classifica os dados através da definição de um hiperplano que melhor diferencia dois grupos. Essa diferenciação é maximizada ao aumentar a margem, ou seja, a distância em ambos os lados desse hiperplano. Ao final, a região delimitada pelo hiperplano com a maior margem possível é utilizada para a análise.

Um dos principais destaques do método SVM é a sua capacidade de encontrar relacionamentos não lineares por meio do uso de uma função de *kernel* (conhecida como *kernel trick*). Em resumo, o *kernel trick* permite que os dados sejam transformados para outra dimensão, o que, em última análise, amplia a margem divisória entre as classes de interesse. A limitação deste método reside na sua tendência ao sobreajuste (*overfitting*).

3.5.1.4 Descida Gradiente Estocástica (SGD)

O algoritmo Stochastic Gradient Descent (SGD) é uma abordagem eficiente para o treinamento de classificadores lineares, sendo amplamente reconhecido por sua eficácia em tarefas de classificação de textos com grandes volumes de dados. Diferente da descida de gradiente tradicional, que processa todo o conjunto de treinamento para realizar uma única atualização de parâmetros, o SGD realiza ajustes de forma iterativa, utilizando apenas um exemplo de treino por vez (ou um pequeno subconjunto). Essa característica torna o processo de aprendizado significativamente mais rápido e menos custoso em termos de

memória, especialmente em cenários de alta dimensionalidade comuns no Processamento de Linguagem Natural (PLN).

No contexto da categorização de documentos, o uso do *SGDClassifier* é vantajoso por permitir a convergência acelerada em problemas nos quais a matriz de termos é esparsa, conforme discutido por [Kabir et al. 2015]. O algoritmo busca minimizar uma função de perda (loss function) por meio de atualizações sucessivas do vetor de pesos, o que o torna uma ferramenta versátil que pode se comportar como diferentes classificadores, como o SVM ou a Regressão Logística, dependendo da função de perda escolhida. Assim, o SGD consolida-se como uma técnica de otimização robusta, capaz de lidar com a complexidade inerente à identificação de padrões em textos de redes sociais, mantendo a escalabilidade necessária para o processamento em larga escala.

3.5.2 Termo Frequência - Frequência Inversa Documento (TF-IDF)

Conforme [Qaiser e Ali 2018], o TF-IDF (*Term Frequency – Inverse Document Frequency*) é uma técnica estatística utilizada para medir a importância de palavras em um documento dentro de uma coleção de textos. A técnica funciona por meio da multiplicação de dois fatores: o **TF**, que conta a frequência de um termo em um texto específico, e o **IDF**, que reduz o peso de palavras muito comuns no *corpus* e valoriza termos raros e mais informativos.

Essa técnica é amplamente aplicada na mineração de textos para identificar palavras-chave e categorizar conteúdos de forma automática. Contudo, sua eficácia depende de uma etapa de pré-processamento para remover elementos sem valor semântico, como códigos HTML e *stopwords*, garantindo que o escore final reflita com precisão os temas centrais analisados.

3.5.3 Validação Cruzada: Processo de Avaliação do Modelo

A validação cruzada utiliza um iterador que fornece pares de índices de treino e teste para dividir os dados de entrada, como nos métodos *K-fold*, *leave-one-out* ou validação cruzada estratificada. Essa técnica permite que o desempenho de um estimador seja avaliado ou que parâmetros sejam selecionados de forma robusta. No ecossistema *Scikit-learn*, esse processo pode ser automatizado através do objeto `GridSearchCV`, no qual o termo CV refere-se especificamente à validação cruzada [Pedregosa et al. 2012].

De acordo com os autores, a técnica de validação cruzada opera através de partições ou divisões, denominadas *k-folds*. Esse particionamento da base de treinamento é essencial para a calibração e ajuste fino dos hiperparâmetros do modelo. O funcionamento dinâmico desse ciclo de divisões e a organização das amostras para avaliação podem ser observados na figura 3.1.

Durante a execução, o sistema seleciona os parâmetros dentro de uma grade especificada para maximizar a pontuação do modelo, delegando funções como predição

e transformação ao estimador já ajustado. Além disso, a validação cruzada pode ser otimizada para certos estimadores ao explorar propriedades específicas, como caminhos de regularização, ou ser integrada a um objeto `Pipeline` para ajustar os parâmetros de todas as etapas do processo (como redução de dimensionalidade e ajuste do modelo) de forma combinada e transparente.




Figura 3.1: Ilustração dos conjuntos de dados sendo utilizados para as etapas de treino e teste gerados no procedimento de validação cruzada K -Fold

3.6 MEDIDAS DE AVALIAÇÃO DE MODELOS DE APRENDIZADO DE MÁQUINA

3.6.1 Matriz de Confusão

A avaliação do desempenho dos modelos de aprendizado supervisionado é realizada, primordialmente, por meio da Matriz de Confusão [Hossin e M.N 2015]. Esta ferramenta funciona como uma tabela que mapeia as predições efetuadas pelo sistema em relação aos rótulos reais presentes no conjunto de dados, permitindo identificar não apenas a eficácia global de acertos, mas também a natureza específica dos erros cometidos pelo classificador. A estrutura desta matriz organiza os resultados em quatro quadrantes fundamentais:

- Verdadeiros Positivos (VP): Referem-se às mensagens de conteúdo misógino que foram corretamente identificadas pelo modelo;
- Verdadeiros Negativos (VN): Compreendem as mensagens neutras ou não misóginas que o sistema classificou adequadamente como negativas;
- Falsos Positivos (FP): Ocorrem quando o modelo rotula indevidamente uma mensagem neutra como misógina, caracterizando o erro do Tipo I;
- Falsos Negativos (FN): Acontecem quando um conteúdo misógino não é detectado pelo sistema, sendo classificado erroneamente como neutro, o que configura o erro do Tipo II.

A análise detalhada desta matriz é o que viabiliza o cálculo de métricas cruciais, como precisão e revocação. No âmbito desta pesquisa, tal ferramenta é essencial para demonstrar as tendências do modelo, revelando se há uma maior dificuldade em detectar o discurso de ódio (gerando falsos negativos) ou se o sistema apresenta um rigor excessivo (gerando falsos positivos). Com o objetivo de ilustrar a matriz de Confusão descrita em [Hossin e M.N 2015], adotam-se os conceitos relacionados por meio da figura 3.2.




Figura 3.2: Matriz de Confusão

3.6.2 Acurácia

É a métrica mais direta, representando a proporção de predições corretas (tanto positivas quanto negativas) em relação ao total de casos analisados [Ricci et al. 2010]. Representada na equação 3.1 o racional para a acurácia.

$$\text{Acurácia} = \frac{\text{VP} + \text{VN}}{\text{Total}} \quad (3.1)$$

3.6.3 Precisão e Revocação

A Precisão indica a capacidade do modelo de não classificar como positiva uma amostra que pertence à classe negativa. Em outros termos, ela determina a proporção de instâncias classificadas como positivas que realmente pertencem a essa categoria [Ricci et al. 2010]. O racional matemático para o cálculo da Precisão está apresentado na equação 3.2.

$$\text{Precisão} = \frac{\text{VP}}{\text{VP} + \text{FP}} \quad (3.2)$$

Já a Revocação mede a capacidade do modelo em encontrar todas as instâncias pertencentes à classe positiva. Isto é, de todos os casos positivos reais existentes no conjunto de dados, determina qual proporção o classificador conseguiu identificar corretamente [Ricci et al. 2010]. O racional matemático para a Revocação está representado na equação 3.3.

$$\text{Revocação} = \frac{VP}{VP + FN} \quad (3.3)$$

3.6.4 F-mensure

É a média harmônica entre a Precisão e a Revocação, fornecendo uma métrica única que equilibra ambas [Ricci et al. 2010]. Representada na equação 3.4 está o racional para a F-Mensure.

$$F_1 = \frac{2 \times \text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad (3.4)$$

4 METODOLOGIA

O presente estudo tem como objetivo expandir os léxicos específicos para a detecção de misoginia em língua portuguesa, com ênfase em publicações extraídas de redes sociais que pertencem ao contexto da sociedade e cultura brasileira. A proposta prevê a elaboração de um léxico expandido e a consolidação de um corpus anotado para o domínio, visando validar a eficácia desse material no suporte à avaliação experimental de modelos de aprendizado supervisionado, que podem ser aplicados na classificação de textos publicados no Twitter, com potencial para uso em outras redes sociais, especialmente as de microblog.

Nesta seção, são detalhados os aspectos da metodologia adotada para o desenvolvimento da pesquisa. A metodologia é estruturada em quatro grandes etapas: criação do léxico de termos misóginos 4.1, coleta de mensagens em redes sociais 4.2, método de rotulagem dos textos misóginos 4.3 e avaliação inicial de modelos supervisionados de classificação 4.4. As etapas são ilustradas pela Figura 4.1.




Figura 4.1: Diagrama exemplificando a metodologia aplicada no estudo.

4.1 CRIAÇÃO DO LÉXICO DE TERMOS MISÓGINOS

O estágio inicial da investigação concentra-se na estruturação de um repositório especializado em termos misóginos no contexto do português brasileiro. Este processo parte da consolidação de uma base derivada de repositórios preexistentes e bibliografia de referência ([Hatebase 2024],[Zanello e Romero 2012]), servindo como fundamento para uma posterior expansão incremental. Com o intuito de atualizar e regionalizar este vocabulário, aplica-se um instrumento de coleta desenhado para a elicitacão de novas expressões do domínio. A abordagem metodológica consiste em um processo colaborativo no qual os participantes são expostos ao conjunto lexical inicial tanto para a validação dos termos já catalogados quanto para a proposição de novos itens e variantes linguísticas não contemplados originalmente.

Para garantir essa ampliação do léxico, utiliza-se um instrumento de coleta ela-

borado especificamente para coletar novas expressões no domínio da misoginia junto a colaboradores. O funcionamento deste instrumento de coleta consiste em apresentar o conjunto lexical inicial aos participantes, instigando-os a atuar em duas frentes: na validação das expressões no domínio já mapeadas e na proposição de novas formas de manifestação da misoginia não registradas anteriormente. Essa integração entre a base preexistente e o conhecimento prático dos participantes é o que viabiliza a descoberta de expressões de uso corrente no cenário brasileiro, mitigando o viés de listas genéricas ou estrangeiras e mantendo mais informações regionais das mesmas.

O processamento das contribuições obtidas segue um rigoroso fluxo de consolidação lexical. Após a coleta, as sugestões passam por etapas de segmentação, normalização e análise de frequência. Para garantir a robustez do recurso final, a inclusão de qualquer item no léxico expandido é condicionada a um critério de filtragem por recorrência. Esse mecanismo exige que cada termo ou expressão atinja um ponto de corte de recorrência pré-estabelecido, assegurando que o léxico final seja composto por unidades linguísticas representativas e desprovidas de ambiguidades ou termos puramente individuais. Ao final deste processo, o léxico expandido constitui o parâmetro técnico para a extração direcionada de mensagens nas redes sociais.

4.2 CRIAÇÃO DO CORPUS DE REDES SOCIAIS

A segunda etapa, após a estruturação do vocabulário, tem como finalidade a criação de um corpus de mensagens textuais extraídas de redes sociais com base no léxico expandido proveniente da etapa anterior. O processo configura-se como um procedimento de coleta baseado em palavras-chave, no qual cada item do léxico atua como um indexador de busca para as publicações. Esse fluxo consolida o material bruto de recuperação orientada, servindo de base para as etapas de análise e de rotulagem posteriores.

Após essa extração inicial, o material passa por uma etapa de organização do corpus. O objetivo nesta fase é preparar o conjunto de dados para que ele possa ser processado corretamente. Esse processo inclui a reunião de todas as mensagens recuperadas, a exclusão de conteúdos duplicados e a padronização do formato em que os textos são salvos. Essas ações são fundamentais para garantir que o corpus seja consistente e esteja pronto para as ferramentas de computação.

Ressalta-se que esta etapa do processo metodológico não pressupõe a análise definitiva dos conteúdos. A criação do corpus é caracterizada estritamente como uma etapa de recuperação orientada, o que significa que o sistema apenas localiza mensagens com potencial relevância. O fato de um termo estar presente no texto não garante, de imediato, a existência de um discurso misógino. Assim, o foco desta etapa é reunir um universo de dados pertinente, cuja classificação final é determinada apenas nas etapas posteriores de rotulagem.

4.3 MÉTODO DE ROTULAGEM DOS TEXTOS MISÓGINOS

A terceira etapa da metodologia dedica-se à rotulagem das mensagens recuperadas, com o propósito de converter o material bruto em um conjunto de dados rotulados. Parte-se da premissa de que a ocorrência isolada de termos do léxico não determina, necessariamente, a natureza misógina de um texto, visto que tais termos podem assumir diferentes funções discursivas conforme o contexto. Para superar essa limitação e incorporar o julgamento contextual à análise, adota-se um procedimento de rotulagem humana.

A estratégia de amostragem para esta fase prioriza publicações que contêm os termos de maior recorrência e consenso identificados nas etapas anteriores, equilibrando expressões já validadas e novos léxicos sugeridos pelos colaboradores. O instrumento de coleta é estruturado para apresentar subconjuntos de mensagens aos participantes de maneira aleatória e sequencial, visando mitigar vieses de ordem e reduzir o efeito de fadiga, o que garante maior integridade ao processo de rotulagem. Além da avaliação técnica, o instrumento segue rigorosos protocolos éticos, coletando dados sociodemográficos e assegurando a concordância com o Termo de Consentimento Livre e Esclarecido.

Durante a avaliação, os colaboradores analisam os textos individualmente e realizam a classificação dos mesmos em categorias que distinguem entre conteúdos misóginos, não misóginos ou indeterminados. Com a consolidação das respostas, estrutura-se a base de referência da pesquisa. Para viabilizar a experimentação supervisionada, este conjunto de dados dá origem a um subconjunto binário, composto apenas pelas instâncias classificadas nas categorias decisórias do protocolo. Esse alinhamento reflete a interpretação humana sobre o fenômeno e serve como o padrão de referência para o treinamento e teste dos modelos computacionais.

4.4 AVALIAÇÃO INICIAL DE MODELOS SUPERVISIONADOS DE CLASSIFICAÇÃO

A fase final da metodologia dedica-se à validação experimental do conjunto de dados, buscando mensurar o potencial do corpus anotado em viabilizar a detecção automatizada de misoginia. Nesta etapa, o foco concentra-se na curadoria de dados para a tarefa computacional de classificação, com o objetivo de verificar se as relações estabelecidas durante a rotulação humana são aprendidas e replicadas por algoritmos de aprendizagem supervisionada.

Para que os modelos processem o conteúdo textual, implementa-se um fluxo de preparação e transformação de dados que compreende as seguintes subetapas:

- **Processamento e Tratamento de Texto:** O material de entrada é submetido a técnicas de limpeza e padronização, visando a redução de ruídos inerentes à linguagem

das redes sociais. Esse tratamento assegura que o algoritmo foque em características linguísticas estruturantes, eliminando variações irrelevantes que prejudicam a aprendizagem.

- **Vetorização e Representação Numérica:** Como os algoritmos operam sobre bases matemáticas, aplica-se uma técnica de vetorização para converter as mensagens em atributos numéricos. Este processo busca preservar a relevância semântica e estatística das palavras, transformando o texto em vetores compatíveis com o processamento algorítmico.
- **Treinamento e Ajuste de Modelos:** Sobre essa base vetorial, os algoritmos de classificação supervisionada são ajustados. O modelo busca estabelecer correlações entre os padrões identificados nos atributos textuais e os rótulos atribuídos pelos participantes humanos na fase anterior.

A condução da modelagem segue um protocolo rigoroso de experimentação, no qual diferentes arquiteturas de algoritmos são testadas e comparadas. Para garantir a confiabilidade dos resultados, utiliza-se um método de avaliação que permite estimar a capacidade de generalização dos modelos, assegurando que o sistema não apenas memorize os dados de treino, mas consiga identificar o discurso misógino em novas instâncias. Esse procedimento permite determinar a configuração técnica mais eficaz para os desafios específicos da língua portuguesa e do contexto brasileiro.

5 AVALIAÇÃO EXPERIMENTAL E RESULTADOS

Nesta parte do trabalho, são detalhados os resultados alcançados ao longo das fases de execução, o que inclui a elaboração do léxico de termos misóginos, os procedimentos de extração de dados da plataforma *Twitter/X* e o processo de rotulação das mensagens coletadas. Além disso, apresenta-se o desempenho preliminar dos modelos de aprendizado supervisionado aplicados à tarefa de classificação dos textos. Essas etapas fornecem uma base experimental sólida para a análise computacional da misoginia no contexto do português brasileiro, comprovando que o fluxo de trabalho adotado é capaz de gerar evidências consistentes para o estudo desse fenômeno.

5.1 CONSTRUÇÃO DO LÉXICO DE TERMOS MISÓGINOS

A fase dedicada à expansão do repertório de termos misóginos ocorreu por meio da aplicação de um questionário digital, utilizando o Google Forms, conduzido durante o período de março a junho de 2024. Ao finalizar essa coleta, registrou-se a colaboração de 143 voluntários que contribuíram para a base de dados. A caracterização do grupo participante revelou uma predominância de mulheres cisgênero, que representaram (68,5%) do total da amostra.

No que diz respeito à distribuição etária, observou-se que a maioria dos participantes (53%) estava concentrada no intervalo entre 18 e 30 anos. Essa composição demográfica é considerada estratégica para a pesquisa, visto que o foco do trabalho são os ataques e manifestações de ódio que atingem o público feminino nas plataformas digitais. Assim, a coleta reflete a perspectiva de um grupo que vivencia diretamente as dinâmicas discursivas analisadas neste estudo.

Durante a fase de validação do repertório inicial, os colaboradores analisaram os 16 termos iniciais para determinar se cada um possuía conotação misógina. Para definir quais expressões seriam mantidas, utilizou-se um critério de seleção fundamentado na lógica de Pareto (proporção 80/20), estabelecendo que seriam integrados ao léxico final apenas os itens identificados como misóginos por, no mínimo, 20% dos participantes. Considerando o total da amostra, esse ponto de corte foi fixado em 29 indicações por termo.

Como resultado dessa filtragem, 12 termos atingiram a frequência necessária e foram validados: *piranha* (129), *puta* (126), *galinha* (118), *baranga* (117), *piriguete* (115), *baleia* (93), *sapatão* (91), *perua* (76), *prostituta* (68), *mulata* (67), *rameira* (63) e *cabra* (37). Em contrapartida, as palavras *camafeu*, *fufa*, *galdéria* e *pega* foram descartadas por não alcançarem o mínimo de 29 ocorrências. Essa baixa aceitação indica que tais termos possuem pouca circulação no português brasileiro atual ou que seu uso está restrito a contextos muito específicos e variedades regionais limitadas.

Durante a fase de sugestões abertas, os colaboradores listaram novos termos e expressões que se relacionavam ao conceito de misoginia. Esses dados textuais passaram por uma etapa de pré-processamento, que incluiu a segmentação dos termos, a normalização da escrita e a contabilização das frequências de cada palavra sugerida. O objetivo foi organizar as contribuições brutas em um formato passível de análise quantitativa e qualitativa.

Para garantir a relevância das novas entradas, estabeleceu-se como critério de seleção a inclusão apenas de itens citados, ao menos, três vezes. Esse ponto de corte foi definido por ser superior à média de recorrência geral das sugestões, que foi de 2,12 aparições por termo. Como resultado dessa metodologia, 20 novos termos foram validados e integrados ao repertório final do estudo.

O resultado final desta investigação é o léxico denominado **LexMis-BR**, detalhado na Tabela 5.1, composto por 32 termos e expressões, listadas de acordo com o volume decrescente de menções recebidas. No conjunto apresentado, as palavras assinaladas com um asterisco representam o repertório inicial utilizado no estudo, enquanto os demais itens foram propostos de maneira voluntária pelos participantes durante a pesquisa. Essa expansão permitiu que o recurso final dobrasse de tamanho em relação à lista inicial, garantindo uma cobertura mais fiel às expressões utilizadas atualmente no português brasileiro, sobretudo em ambientes de redes sociais.

Tabela 5.1: Léxico final (LexMis-BR) em ordem decrescente de ocorrência.

piranha* (129)	puta* (126)	galinha* (118)	baranga* (117)	piriguete* (115)
baleia* (93)	sapatão* (91)	perua* (76)	prostituta* (68)	mulata* (67)
rameira* (63)	cabra* (37)	vadia (30)	vagabunda (22)	vaca (12)
histórica (9)	cachorra (9)	louca (8)	mulherzinha (8)	burra (4)
rapariga (4)	desequilibrada (4)	biscate (4)	mal comida (4)	mal amada (4)
maluca (4)	quenga (3)	mulher fácil (3)	cadela (3)	velha (3)
descontrolada (3)	doida (3)			

Os dados indicados entre parênteses revelam a contagem de participantes que validaram cada termo dentro de um contexto misógino. Observa-se que os itens originados do formulário inicial apresentam, em geral, frequências superiores por terem sido expostos diretamente à avaliação de todos os colaboradores. Já as expressões sugeridas no campo aberto tendem a registrar valores menores, devido à natureza diversa das respostas. No entanto, destaca-se que termos como *vadia*, citado 30 vezes, alcançaram um patamar de reconhecimento próximo a termos do repertório base, como *cabra*, validado por 37 pessoas. Isso reforça a importância da etapa de sugestões para capturar vocábulos com forte carga semântica no uso cotidiano.

Para além da expansão quantitativa de termos, o léxico final revela padrões semânticos significativos nas manifestações ofensivas. Nota-se uma forte concentração de insultos voltados à sexualidade e ao comportamento social feminino, exemplificados por termos como *puta*, *piriguete*, *piranha*, *vadia* e *vagabunda*. Adicionalmente, destacam-se

vocábulos direcionados à desqualificação da saúde mental e do equilíbrio emocional, tais como *histérica*, *louca*, *maluca*, *desequilibrada* e *descontrolada*, além do uso recorrente de expressões que promovem a animalização simbólica da mulher, ocorrendo em formas como *galinha*, *baleia*, *vaca*, *cachorra* e *piranha*.

De modo geral, os dados desta fase confirmam que a colaboração direta dos falantes foi fundamental para aumentar a abrangência do recurso, integrando expressões que refletem o uso cotidiano no português brasileiro. Esse fator é essencial no estudo da misoginia, campo no qual gírias, metáforas pejorativas e variações regionais são ferramentas centrais do discurso de ódio. Dessa forma, o **LexMis-BR** não apenas cresceu em volume, mas também validou a importância de se construir ferramentas linguísticas sensíveis às particularidades socioculturais do Brasil para uma análise computacional mais precisa.

5.2 COLETA E CARACTERIZAÇÃO DOS TEXTOS

Utilizando o repertório **LexMis-BR** como base, desenvolveu-se à coleta de mensagens na plataforma Twitter/X para formar um conjunto de dados textuais com potencial relevância para o estudo da misoginia. Esse estágio envolveu um método de extração automatizada, estruturado a partir dos 32 termos detalhados na Tabela 5.1. Para cada termo presente no léxico, estabeleceu-se um limite de 100 publicações, filtrando-se apenas conteúdos em língua portuguesa que apresentassem ao menos cinco curtidas, além de desconsiderar postagens contendo links ou que fossem respostas a outros usuários.

O período de coleta foi restrito ao primeiro semestre de 2024, resultando em um banco de dados denominado **MisoginiaBR-Coleta**, que totalizou 3200 mensagens obtidas por meio de buscas direcionadas pelo léxico. Essa metodologia foi adotada para assegurar que todos os termos do **LexMis-BR** tivessem uma representatividade equilibrada na amostra final. Além disso, o volume de dados foi planejado para tornar viável a etapa subsequente de rotulação manual, garantindo que o conjunto fosse robusto o suficiente para a análise sem comprometer a execução técnica do projeto.

A metodologia de coleta fundamenta-se na premissa de que a utilização de termos específicos do léxico eleva as chances de recuperar mensagens com potencial misógino. Entretanto, é importante ressaltar que a existência dessas palavras em um texto não assegura, de forma isolada, que a publicação se configure obrigatoriamente como um discurso de ódio contra mulheres. Fatores como ironia, citações de terceiros ou o uso dos termos em contextos distintos podem influenciar o sentido real da mensagem, exigindo uma análise mais profunda do conteúdo coletado.

Dessa maneira, o conjunto de dados **MisoginiaBR-Coleta** deve ser interpretado como um corpus preliminar de mensagens relevantes para o estudo, servindo como base para as fases posteriores da pesquisa. A classificação definitiva de cada item depende obrigatoriamente da etapa de rotulação humana, que fornecerá o julgamento necessário

para validar se as ocorrências recuperadas de forma automatizada correspondem, de fato, a manifestações de misoginia. Esse refinamento é o que permitirá a criação de um conjunto de dados padrão-ouro para o treinamento dos modelos de aprendizado de máquina.

5.3 ROTULAÇÃO DOS TEXTOS E COMPOSIÇÃO DO CONJUNTO DE DADOS ROTULADOS

Com o objetivo de equilibrar a viabilidade metodológica e a relevância dos dados, este estudo estabeleceu um recorte estratégico para a fase de rotulação. Assim, a rotulagem manual não foi aplicada à totalidade das mensagens recuperadas para os 32 termos do LexMis-BR, mas concentrou-se em um subconjunto lexical mais expressivo. A seleção priorizou itens de maior impacto em duas vertentes complementares: (i) os cinco vocábulos mais frequentes do inventário inicial documentado na literatura, sendo eles *piranha*, *puta*, *galinha*, *baranga* e *piriguete*; e (ii) os cinco termos com maior recorrência entre as sugestões espontâneas dos voluntários, especificamente *vadia*, *vagabunda*, *vaca*, *histérica* e *cachorra*.

Essa escolha justifica-se pela necessidade de conciliar o rigor científico com o esforço interpretativo exigido dos participantes humanos. Ao focar em termos já consolidados por pesquisas anteriores e em expressões emergentes identificadas pelos próprios falantes, o processo assegura que a análise recaia sobre conteúdos com alta probabilidade de manifestar o discurso misógino no português brasileiro atual. Dessa forma, o procedimento garante a construção de um conjunto de dados robusto e qualitativamente relevante, preservando a eficiência técnica necessária para o cumprimento das etapas seguintes da pesquisa.

A partir dos dez termos priorizados, extraiu-se um subconjunto de 300 *tweets*, composto por 30 mensagens para cada termo. A seleção foi realizada de maneira aleatória a partir do *corpus* original, visando assegurar a diversidade de contextos e garantir que a etapa de rotulação fosse humanamente viável. Esse agrupamento de dados foi designado como MisoginiaBR-10-300, refletindo a amostra de 10 termos do léxico e a totalidade de 300 mensagens que servirão de base para a validação humana.

Para a fase de avaliação, o MisoginiaBR-10-300 foi organizado em dez listas compostas por 30 *tweets* cada, distribuídas de forma aleatória com o intuito de minimizar a fadiga dos colaboradores e evitar possíveis vieses de ordenação. Tal estrutura permitiu que cada participante analisasse integralmente uma lista específica de mensagens. Após essa organização, desenvolveu-se um novo formulário de coleta via *Google Forms*, no qual os voluntários forneciam inicialmente informações sociodemográficas, como gênero, faixa etária e localização, e validavam o Termo de Consentimento Livre e Esclarecido. Posteriormente, o participante realizava a classificação dos 30 textos de sua lista designada; à medida que cada agrupamento de mensagens alcançava o total de cinco respostas, ele era

desativado para que as demais listas fossem priorizadas, garantindo a cobertura uniforme dos dados.

Ao longo do processo de rotulagem, os colaboradores classificaram cada mensagem em uma de três categorias distintas: “Considero misógina”, “Não considero misógina” ou “Não sei definir”. A inclusão da terceira opção visou acolher conteúdos ambíguos, limítrofes ou de interpretação duvidosa, evitando a imposição de escolhas binárias em casos de incerteza. Para a estruturação do banco de dados final, o rótulo atribuído a cada mensagem foi determinado pela visão majoritária dos participantes; nos cenários em que não se atingiu uma maioria simples, o registro foi catalogado separadamente como um caso de empate.

Ao término da fase de coleta, registraram-se 54 participações válidas, o que garantiu o critério de ao menos cinco avaliações por mensagem. Esse método possibilitou a organização de um *corpus* fundamentado no julgamento humano, servindo como a base de referência empírica para a análise de desempenho dos modelos de classificação supervisionada. O conjunto de dados resultante desta etapa foi nomeado **MisoginiaBR-300-rot**.

A análise da distribuição de rótulos nas 300 mensagens do conjunto denominado **MisoginiaBR-300-rot** revela que a maioria das classificações se concentra nas classes “Não considero misógina” (142 textos; 47,3%) e “Considero misógina” (122 textos; 40,7%), totalizando 88,0% da amostra. Por outro lado, 10 textos (3,3%) foram agrupados na categoria “Não sei definir”, enquanto 26 mensagens (8,7%) apresentaram empate entre as opiniões dos participantes. Esses dados confirmam que, embora a estratégia baseada no léxico tenha sido eficaz para filtrar conteúdos pertinentes, a presença isolada de um termo ofensivo não determina obrigatoriamente a existência de um discurso de ódio, funcionando apenas como um guia para a extração inicial.

A prevalência da classe não misógina, somada aos registros de incerteza e empate, evidencia que a validação humana é indispensável para distinguir ofensas reais de usos neutros ou ambíguos da língua. Tais resultados atendem ao objetivo central da pesquisa ao demonstrar que, embora a recuperação lexical seja uma fase valiosa na estruturação do *corpus*, a confiabilidade do recurso final para o treinamento de modelos depende diretamente da curadoria manual. Dessa forma, a rotulação humana atua como o filtro necessário para transformar uma coleta bruta em um conjunto de dados anotado com rigor acadêmico.

5.4 CLASSIFICAÇÃO SUPERVISIONADA DOS TEXTOS

A fase de classificação supervisionada foi estruturada a partir do banco de dados rotulado, selecionando-se exclusivamente as mensagens pertencentes às categorias “Considero misógina” e “Não considero misógina”. Com essa abordagem, as ocorrências classificadas como empate ou “Não sei definir” foram excluídas da tarefa binária. Esse

filtro resultou em um conjunto de 264 textos, sendo que 53 instâncias (20%) foram destinadas ao teste final em *holdout*, enquanto as 211 restantes (80%) foram aplicadas no treinamento e na validação interna. Tal organização permitiu tratar o problema como uma classificação binária supervisionada, distinguindo claramente o ajuste do modelo do teste de generalização.

No que diz respeito ao subconjunto de treinamento, utilizou-se a técnica de validação cruzada estratificada e repetida, com 5 partições e 3 repetições, perfazendo um total de 15 execuções para cada configuração testada. A escolha dos melhores parâmetros foi guiada pela métrica F1-mensure, por ser uma medida que avalia o desempenho do classificador de maneira equilibrada entre as duas classes, mitigando o impacto da classe majoritária nos resultados. Adicionalmente, computaram-se as métricas de precisão e revocação, possibilitando uma investigação mais minuciosa sobre a eficácia dos modelos desenvolvidos.

Nesta etapa, foram testados quatro algoritmos frequentemente utilizados em problemas de classificação de textos: *Regressão Logística*, *LinearSVC*, *SGDClassifier* e *Naive Bayes*. Enquanto os três primeiros modelos constituem opções lineares robustas para lidar com dados textuais esparsos e de alta dimensionalidade, o último destaca-se por sua relevância em abordagens fundamentadas em frequência. A Tabela 5.2 apresenta um resumo dos classificadores aplicados e os respectivos intervalos de busca para otimização, utilizando uma nomenclatura simplificada para os parâmetros.

Tabela 5.2: Classificadores e grades de parâmetros dos experimentos.

Algoritmo	Grade de parâmetros avaliada
<i>Regressão Logística</i>	analisador $\in \{\text{word}, \text{char_wb}\}$; faixa de n-gramas $\in \{(1, 1), (1, 2), (1, 3), (3, 5), (3, 6), (4, 6)\}$; frequência documental mínima $\in \{1, 2, 3\}$; escala sublinear de frequência $\in \{\text{True}, \text{False}\}$; $C \in \{0.1, 0.5, 1.0, 2.0, 5.0, 10.0\}$; ponderação de classes $\in \{\text{None}, \text{balanced}\}$
<i>Naive Bayes</i>	analisador = word ; faixa de n-gramas = (1, 2); frequência documental mínima $\in \{1, 2\}$; escala sublinear de frequência $\in \{\text{True}, \text{False}\}$; $\alpha \in \{0.1, 0.5, 1.0, 2.0, 5.0\}$
<i>SGD Classifier</i>	analisador $\in \{\text{word}, \text{char_wb}\}$; faixa de n-gramas $\in \{(1, 2), (3, 5)\}$; frequência documental mínima = 2; escala sublinear de frequência $\in \{\text{True}, \text{False}\}$; função de perda $\in \{\text{hinge}, \text{log_loss}\}$; $\alpha \in \{10^{-5}, 10^{-4}, 10^{-3}\}$; ponderação de classes $\in \{\text{None}, \text{balanced}\}$
<i>Linear SVC</i>	analisador = word ; faixa de n-gramas = (1, 2); frequência documental mínima $\in \{1, 2\}$; escala sublinear de frequência $\in \{\text{True}, \text{False}\}$; $C \in \{0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0, 10.0\}$; ponderação de classes $\in \{\text{None}, \text{balanced}\}$

A definição dessas arquiteturas permitiu comparar diferentes estratégias de aprendizado para identificar qual abordagem melhor se adapta às características do *corpus* rotulado. Ao explorar diversos hiperparâmetros, buscou-se maximizar a capacidade de generalização dos modelos, garantindo que a escolha final fosse baseada em uma análise experimental rigorosa. Esse procedimento é essencial para validar a eficácia dos algoritmos diante das nuances e desafios específicos da detecção de misoginia em língua portuguesa.

A Tabela 5.3 exibe a comparação direta entre os desempenhos obtidos na valida-

ção cruzada e no teste *holdout* para cada um dos algoritmos avaliados. Os dados revelam que a *Regressão Logística* alcançou o patamar superior de desempenho médio durante a fase de validação, sendo acompanhada de perto pelo *LinearSVC* e pelo *SGDClassifier*. Por sua vez, o *Naive Bayes* apresentou métricas ligeiramente menores, porém, manteve um nível de consistência relevante para a tarefa proposta.

Tabela 5.3: Desempenho dos algoritmos em validação cruzada e *holdout*.

Algoritmo	Treino - validação cruzada				Teste - <i>holdout</i>		
	Precisão	Revocação	F1-macro	Desv. pad.	Precisão	Revocação	F1-macro
<i>Regressão Logística</i>	0,801	0,798	0,798	0,078	0,735	0,730	0,731
<i>LinearSVC</i>	0,793	0,788	0,788	0,090	0,618	0,612	0,611
<i>SGDClassifier</i>	0,789	0,781	0,783	0,073	0,696	0,692	0,693
<i>Naive Bayes</i>	0,781	0,773	0,772	0,076	0,618	0,612	0,611

A predominância da *Regressão Logística* na etapa de validação cruzada assume especial importância, visto que sua configuração mais eficiente se baseou na técnica de TF-IDF aplicada a n-gramas de caracteres do tipo *char_wb*. Esse fato sugere que a identificação de padrões sublexicais foi um fator determinante para distinguir com precisão as mensagens misóginas das não misóginas.

O desempenho máximo foi alcançado com a utilização do parâmetro $C = 1.0$, aliado à ponderação balanceada de classes e a uma frequência documental mínima definida em 3. Adicionalmente, a configuração contou com o uso de uma escala sublinear de frequência e uma representação de n-gramas de caracteres variando entre 4 e 6 posições, o que permitiu capturar nuances morfológicas essenciais para o aprendizado do modelo.

Uma vez definida a configuração ideal para cada algoritmo, realizou-se a medição de desempenho no conjunto de teste em *holdout*. Os dados expostos na Tabela 5.3 confirmam que a *Regressão Logística* manteve a liderança como o modelo mais eficaz, atingindo um F1-mensure de 0,731, sendo sucedida pelo *SGDClassifier*, que registrou 0,693. Por outro lado, o *LinearSVC* e o *Naive Bayes* demonstraram uma capacidade inferior e equivalente no teste final, ambos com uma marca de 0,611 em F1-mensure.

Comparado aos resultados da validação cruzada, o teste em *holdout* forneceu uma perspectiva mais cautelosa sobre o potencial de generalização dos modelos, refletindo os desafios impostos pela dimensão do conjunto de dados analisado. Esse comportamento evidencia a necessidade de avaliações rigorosas para garantir que as previsões do sistema se mantenham consistentes em cenários reais de detecção de misoginia.

A análise detalhada da *Regressão Logística*, que se consolidou como o modelo de maior eficácia no conjunto de teste, está exposta na Tabela 5.4. Durante a fase de *holdout*, o classificador atingiu uma acurácia de 0,736 e um F1-macro de 0,731. Ao observar a classe “Considero misógina”, registraram-se valores de 0,727 para precisão, 0,667 para revocação e um F1-score de 0,696. Em contrapartida, a classe “Não considero misógina” apresentou métricas superiores, com 0,742 de precisão, 0,793 de revocação e 0,767 de F1-score.

Esses indicadores demonstram que a capacidade preditiva do modelo para a classe

Tabela 5.4: Desempenho da *Regressão Logística* no teste *holdout*.

Classe	Precisão	Revocação	F1-score	VP	FP	FN
Considero misógina	0,727	0,667	0,696	16	6	8
Não considero misógina	0,742	0,793	0,767	23	8	6
Média macro	0,735	0,730	0,731	-	-	-

misógina foi ligeiramente reduzida em comparação à classe não misógina, com uma diferença mais acentuada no índice de revocação. Os elementos da matriz de confusão, também detalhados na referida tabela, confirmam que o sistema obteve um desempenho mais robusto na identificação de conteúdos que não configuram ódio contra mulheres, demonstrando maior facilidade em reconhecer corretamente as instâncias negativas do domínio.

Ao analisar os resultados, observa-se que, das 29 instâncias pertencentes à classe “Não considero misógina”, o modelo classificou corretamente 23 casos, enquanto 6 foram indevidamente atribuídos à categoria oposta. No que se refere às 24 instâncias reais da classe “Considero misógina”, o classificador identificou corretamente 16 mensagens, mas falhou ao rotular 8 delas como não misóginas. Esses números refletem a distribuição dos acertos e erros do sistema, evidenciando uma precisão ligeiramente maior na detecção de textos que não apresentam conteúdo ofensivo em comparação àqueles que manifestam misoginia.

Essa constatação indica que a categoria “Considero misógina” impõe um desafio mais acentuado ao processo de classificação supervisionada. Tal fenômeno é evidenciado pelo comportamento da matriz de confusão, na qual a incidência de falsos negativos é proporcionalmente superior nesta classe em comparação à sua contraparte. Esse cenário é condizente com a natureza dos dados analisados, que frequentemente incluem enunciados menos prototípicos, dotados de maior ambiguidade ou que demandam um elevado grau de inferência contextual para serem corretamente interpretados pelo modelo. Dessa forma, a disparidade identificada no desempenho reafirma tanto a complexidade da tarefa quanto a eficácia da abordagem metodológica estabelecida nesta pesquisa, que prioriza a curadoria manual após a extração léxica e antes do processamento por aprendizado de máquina.

De maneira integrada, os achados demonstram que o *LexMis-BR* foi capaz de expandir a abrangência terminológica da área, enquanto a extração direcionada logrou êxito em compilar um *corpus* inicial relevante. Além disso, a fase de rotulação humana explicitou as restrições de uma classificação fundamentada estritamente em vocabulário, onde a etapa de aprendizado supervisionado confirmou a viabilidade do conjunto de dados para experimentações iniciais. De modo geral, as técnicas lineares clássicas, com destaque para a *Regressão Logística* e o *SGDClassifier*, foram as que entregaram os desempenhos mais consistentes diante das características deste conjunto de dados.

6 CONCLUSÃO

Este estudo buscou contribuir para o enfrentamento da violência de gênero digital ao propor a construção de recursos e metodologias dedicados à detecção de misoginia em textos curtos no português do Brasil. Os resultados obtidos evidenciam que combinar a recuperação lexical ao julgamento de avaliadores humanos é um caminho eficaz para estruturar bases de dados consistentes, fornecendo um suporte empírico robusto para o avanço dos estudos computacionais nessa área.

O principal achado deste estudo reside na demonstração de que, embora a recuperação baseada em léxicos seja eficaz para orientar a coleta de dados e a construção do corpus, ela não substitui a validação humana na consolidação de um conjunto anotado confiável. A experiência mostrou que a simples presença de termos do léxico é insuficiente como critério de decisão final devido à ambiguidade inerente aos enunciados e às nuances do discurso nas redes sociais. Assim, o julgamento contextual humano revelou-se indispensável para distinguir ofensas reais de usos neutros ou indeterminados da língua.

Quanto aos objetivos específicos, o trabalho obteve êxito na criação do léxico expandido LexMis-BR, que superou as limitações das bases internacionais ao incorporar a competência linguística de falantes nativos e capturar expressões regionais correntes. A fase de avaliação experimental confirmou que o conjunto de dados produzido sustenta tarefas de classificação supervisionada. Algoritmos lineares clássicos, com destaque para a Regressão Logística, demonstraram desempenho consistente, provando que a metodologia adotada é viável para a identificação de padrões misóginos em larga escala.

Apesar dos resultados promissores alcançados por esta metodologia, algumas limitações técnicas e procedimentais foram identificadas durante a execução do projeto, as quais servem como diretrizes para investigações subsequentes. Primeiramente, destaca-se a natureza extremamente dinâmica da linguagem em ambientes de redes sociais. A constante evolução do dialeto digital e das gírias ofensivas exige que o léxico LexMis-BR e as bases de dados associadas passem por processos de atualização contínua, evitando a obsolescência do sistema diante de novas formas de discurso misógeno.

Um ponto crítico a ser considerado em pesquisas futuras diz respeito ao viés amostral dos participantes envolvidos na construção do léxico e na rotulagem do corpus. Observou-se uma concentração significativa de participantes residentes na região Sudeste do Brasil, o que pode restringir a representatividade de variações linguísticas, gírias e expressões regionais típicas de outras partes do país. Para mitigar esse viés e garantir que a ferramenta possua um alcance verdadeiramente nacional, é recomendável que as próximas etapas da pesquisa busquem uma amostragem mais equilibrada, integrando colaboradores de diversas regiões para capturar a pluralidade sociocultural brasileira na identificação do ódio digital.

No que tange à robustez estatística, a expansão do volume de textos rotulados

é uma prioridade. Embora o conjunto de dados atual tenha se mostrado suficiente para avaliações iniciais, o aumento do número de mensagens e a inclusão de um corpo mais amplo de participantes permitiriam reduzir subjetividades e elevar o índice de concordância nas classes decisórias.

Quanto à evolução da modelagem computacional, sugere-se a exploração de arquiteturas mais complexas. Além dos modelos lineares clássicos abordados, como a Regressão Logística e o SGDClassifier, a área oferece oportunidades para a aplicação de:

- **Classificadores Ensemble:** Uso de algoritmos como Random Forest, Adaptive Boosting e Gradient Boosting para combinar diferentes estimadores e melhorar o desempenho global;
- **Redes Neurais Profundas (Deep Learning):** Implementação de modelos que permitem capturar relações não lineares mais profundas em grandes volumes de dados;
- **IA Generativa e Modelos de Linguagem de Larga Escala (LLMs):** Investigar o uso de modelos generativos para a tarefa de classificação e rotulagem, comparando sua eficiência em relação aos modelos supervisionados tradicionais. Esta análise deve considerar o compromisso entre a precisão na detecção de nuances contextuais e os custos computacionais e financeiros associados ao uso de APIs de modelos proprietários em comparação ao treinamento de modelos open-source.

Em suma, este TCC reafirma o compromisso com a proteção da dignidade da mulher no ambiente virtual. Ao fornecer um método que une rigor ético, curadoria linguística e modelagem computacional, a pesquisa entrega uma base sólida para o aprimoramento de ferramentas de moderação de conteúdo no cenário sociolinguístico brasileiro.

7 APÊNDICE A - TERMO DE CONSENTIMENTO LIVRE E ESCLARECIDO E QUESTIONÁRIO APLICADO AOS PARTICIPANTES

TERMO DE CONSENTIMENTO LIVRE E ESCLARECIDO

A presente pesquisa, denominada Léxico de termos misóginos para a identificação de misoginia em mensagens textuais, tem por objetivo a construção de um Léxico de Termos misóginos em português do Brasil. A expectativa é de que a pesquisa possa contribuir com a construção de um método de identificação automática de conteúdos de discurso de ódio contra mulheres.

Os possíveis benefícios dessa pesquisa são: 1) Referencial bibliográfico para estudos sobre a misoginia; 2) Publicação e disponibilização dos conteúdos textuais rotulados para treinamento de futuros modelos de classificação de textos, como no caso de aprendizado de máquina; 3) Contribuir com a construção de método de identificação automática de conteúdos de discurso de ódio misógino.

A pesquisa possui o seguinte risco: (1) os indivíduos acharem inapropriado responder ao questionário. Como mitigação a esse risco, o participante recebe o documento de Termo de Consentimento Livre e Esclarecido (TCLE) para que ele possa ter conhecimento da pesquisa e concordar ou não com sua participação. Somente os indivíduos que concordarem com o TCLE participarão da pesquisa. Os resultados do estudo serão divulgados exclusivamente pelos pesquisadores em formato de relatórios e/ou artigos científicos.

A pesquisa está sendo desenvolvida no âmbito do DEPIN (Departamento de Informática), no curso de Graduação em Ciência da Computação do CEFET/RJ, orientada pelo professor Gustavo Guedes.

Pesquisador

Nome completo: João Victor Machado Rangel

E-mail: joao.rangel.1@aluno.cefet-rj.br.

Professor Orientador

Nome completo: Gustavo Paiva Guedes e Silva

E-mail: gustavo.guedes@cefet-rj.br.

Se você é maior de 18 anos, convidamos você a participar desse estudo. Sua participação é voluntária e você poderá desistir a qualquer momento. Sua participação no estudo não implicará custos adicionais, não terá qualquer despesa com a realização dos procedimentos previstos nesse estudo. Também não haverá nenhuma forma de benefício acadêmico ou financeiro pela sua participação.

É garantido o direito à indenização diante de eventuais danos decorrentes da pesquisa. O Comitê de Ética em Pesquisa (CEP) da Universidade Salgado de Oliveira - ASOEC - UNIVERSO encontra-se à disposição para eventuais esclarecimentos éticos e outras providências que se façam necessárias (cepuniverso@nt.universo.edu.br - Telefone: (21) 2138-4983). Endereço: Marechal Deodoro, 263 Bl. B - térreo, Centro - Niterói.

Compreendo que posso me retirar do estudo a qualquer momento, sem sofrer qualquer penalidade.

Marcando "sim" e clicando no botão "próxima", dou meu consentimento de livre e espontânea vontade para participar desse estudo e garanto responder a essa pesquisa de forma honesta para contribuir ao máximo com os resultados propostos.

1. Diante das explicações você acha que está suficientemente informado(a) a respeito da pesquisa que será realizada e concorda de livre e espontânea vontade em participar, como colaborador ?

[(a)]

(a) Sim

(b) Não

7.1 DADOS PESSOAIS

1. Qual a sua idade?

2. Qual sua identidade de gênero?

[(a)]

(a) Homem cis

(b) Mulher cis

(c) Homem trans

(d) Mulher trans

(e) Não-binário

(f) Agênero

(g) Outra

3. Em que estado você viveu a maior parte da sua vida?

[(a)]

(a) (Opções dos estados do Brasil)

4. Em que estado você vive atualmente?

[(a)]

(a) (Opções dos estados do Brasil)

7.2 LÉXICO DE TERMOS MISÓGINOS

1. Misoginia é o sentimento de aversão ao feminino, que se traduz com comportamentos, atitudes, discursos que visam a manutenção das desigualdades de gênero e fortalece a crença de superioridade masculina (FERREIRA; ALMEIDA, 2023).

Fonte: Ferreira, F. M., & de Almeida, G. M. R. (2023). Criminalizar a misoginia, por quê?. *ECOS-Estudos Contemporâneos da Subjetividade*, 13(1), 10-14.

Dos termos abaixo, quais você considera misóginos? (*pergunta em escala de três pontos: Considero, Não considero, Não conheço/Não sei*)

[(a)]

(a) Puta

(b) Prostituta

(c) Piriguete

(d) Piranha

- (e) Galinha
- (f) Baleia
- (g) Baranga
- (h) Cabra
- (i) Camafeu
- (j) Fufa
- (k) Galdéria
- (l) Mulata
- (m) Pega
- (n) Perua
- (o) Rameira
- (p) Sapatão

2. Você conhece algum outro termo e/ou expressão que podem ser consideradas misóginas? Escreva-os aqui, separados por vírgula:

REFERÊNCIAS

- Balayn et al. 2021 BALAYN, A. et al. Automatic identification of harmful, aggressive, abusive, and offensive language on the web: A survey of technical biases informed by psychology literature. **Trans. Soc. Comput.**, Association for Computing Machinery, New York, NY, USA, v. 4, n. 3, out. 2021. Disponível em: <https://doi-org.ez108.periodicos.capes.gov.br/10.1145/3479158>.
- Biderman 1996 BIDERMAN, M. T. C. Léxico e vocabulário fundamental. Universidade Estadual Paulista (Unesp), v. 40, 1996. ISSN 1981-5794.
- BRASIL 2023 BRASIL. **Senado aprova criminalização da misoginia**. 2023. Portal de Notícias do Senado Federal. Acesso em: 6 maio 2026. Publicado pela Procuradoria Especial da Mulher do Senado. Disponível em: <https://www12.senado.leg.br/institucional/procuradoria/noticias/senado-aprova-criminalizacao-da-misoginia>.
- Carneiro 2012 CARNEIRO, R. Introdução à terminologia: teoria e prática. **Domínios de Linguagem**, v. 5, p. 247–250, 01 2012.
- Fanni et al. 2023 FANNI, S. C. et al. Natural language processing. In: **Introduction to artificial intelligence**. [S.l.]: Springer, 2023. p. 87–99.
- Federal 2023 FEDERAL, S. **Proposta que criminaliza misoginia começa a tramitar no Senado**. Brasília: Agência Senado, 2023. Disponível em: <https://www12.senado.leg.br/noticias/materias/2023/03/07/proposta-que-criminaliza-misoginia-comeca-a-tramitar-no-senado>. Acesso em: 13 abr. 2026.
- Ferreira 2025 FERREIRA, V. Virtual machismos: Origin and characterization of masculinist discourses on brazilian red pill youtube channels; [machismos virtuais: Discursos masculinistas em canais red pill brasileiros de youtube]; [machismos virtuales: origen y caracterización de los discursos masculinistas en los canales de youtube brasileños red pill]. **Ex Aequo**, n. 51, p. 19 – 29, 2025. Cited by: 0; All Open Access, Gold Open Access, Green Open Access. Disponível em: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-105013114580&doi=10.22355%2fexaequo.2025.51.02&partnerID=40&md5=9d3469cbf32c8a89ddc75b89017ccef6>.
- Fogaça 2023 FOGAÇA, A. B. **Discursos misóginos nas redes sociais geram retrocesso nas conquistas feministas**. São Paulo: [s.n.], 2023. Disponível em: <https://jornal.usp.br/atualidades/discursos-misoginos-nas-redes-sociais-geram-retrocesso-nas-conquistas-feministas/>. Acesso em: 13 abr. 2026.
- Hatebase 2024 HATEBASE. Hatebase: A global repository of structured hate speech. 2024. Acesso em: 22 de março de 2026. Disponível em: <https://hatebase.org/>.
- Hossin e M.N 2015 HOSSIN, M.; M.N, S. A review on evaluation metrics for data classification evaluations. **International Journal of Data Mining & Knowledge Management Process**, v. 5, p. 01–11, 03 2015. https://www.researchgate.net/publication/275224157_A_Review_on_Evaluation_Metrics_for_Data_Classification_Evaluations. Acessado em 06 de maio de 2026.

- Kabir et al. 2015 KABIR, F. et al. Bangla text document categorization using stochastic gradient descent (sgd) classifier. In: IEEE. **2015 international conference on cognitive computing and information processing (CCIP)**. [S.l.], 2015. p. 1–4.
- Khder 2021 KHDER, M. A. Web scraping or web crawling: State of art, techniques, approaches and application. **International Journal of Advances in Soft Computing & Its Applications**, v. 13, n. 3, 2021.
- Khyani et al. 2021 KHYANI, D. et al. An interpretation of lemmatization and stemming in natural language processing. **Journal of University of Shanghai for Science and Technology**, v. 22, n. 10, p. 350–357, 2021.
- Koch et al. 2025 KOCH, L. et al. Online misogyny against female candidates in the 2022 brazilian elections: a threat to women’s political representation? **Information Communication and Society**, 2025. Cited by: 2; All Open Access, Hybrid Gold Open Access. Disponível em: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-105014923668&doi=10.1080%2f1369118X.2025.2551604&partnerID=40&md5=f5816984584faa9b0e1fef59dd5976c2>.
- MacAvaney et al. 2019 MACAVANEY, S. et al. Hate speech detection: Challenges and solutions. **PLOS ONE**, Public Library of Science, v. 14, n. 8, p. 1–16, 08 2019. Disponível em: <https://doi.org/10.1371/journal.pone.0221152>.
- Manning e Schütze 1999 MANNING, C. D.; SCHÜTZE, H. **Foundations of Statistical Natural Language Processing**. Cambridge, MA: MIT Press, 1999.
- Martins et al. 2025 MARTINS, V. et al. A misoginia no youtube brasileiro: Um estudo de caso sobre o conteúdo produzido pela comunidade red pill. In: **Proceedings of the Brazilian Symposium on Multimedia and the Web**. [S.l.: s.n.], 2025.
- Monard e Baranauskas 2003 MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. In: **Sistemas Inteligentes Fundamentos e Aplicações**. 1. ed. Barueri-SP: Manole Ltda, 2003. p. 39–56. ISBN 85-204-168.
- Morais e Ambrósio 2007 MORAIS, E. A. M.; AMBRÓSIO, A. P. L. **Mineração de textos**. Goiânia, 2007. 1–30 p.
- Nasteski 2017 NASTESKI, V. An overview of the supervised machine learning methods. **Horizons**. b, v. 4, n. 51-62, p. 56, 2017.
- Pedregosa et al. 2012 PEDREGOSA, F. et al. Scikit-learn: Machine learning in python. **Journal of Machine Learning Research**, v. 12, 01 2012.
- Plath et al. 2022 PLATH, H. O. et al. Detecção de discurso de Ódio contra mulheres em textos em português brasileiro: Construção da base mina-br e modelo de classificação. **Revista Eletrônica de Iniciação Científica em Computação**, v. 20, n. 3, 2022.
- Qaiser e Ali 2018 QAISER, S.; ALI, R. Text mining: use of tf-idf to examine the relevance of words to documents. **International journal of computer applications**, v. 181, n. 1, p. 25–29, 2018.

Rashidi et al. 2019 RASHIDI, H. H. et al. Artificial intelligence and machine learning in pathology: The present landscape of supervised methods. **Academic Pathology**, v. 6, p. 2374289519873088, 2019. ISSN 2374-2895. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2374289521001573>.

Ricci et al. 2010 RICCI, F. et al. **Recommender Systems Handbook**. 1st. ed. Berlin, Heidelberg: Springer-Verlag, 2010. ISBN 0387858199.

Santos 2024. SANTOS, V. discurso de ódio homofóbico no twitter, uma proposta de método de classificação de textos. **Dissertação de mestrado, CEFET-RJ**, 2024.

Sarica e Luo 2021 SARICA, S.; LUO, J. Stopwords in technical language processing. **Plos one**, Public Library of Science San Francisco, CA USA, v. 16, n. 8, p. e0254937, 2021.

Significados 2023 SIGNIFICADOS. **O que é Misoginia (e exemplos de comportamentos misóginos)**. Porto: 7Graus, 2023. Disponível em: <https://www.significados.com.br/misoginia/>. Acesso em: 13 abr. 2026.

Silva 2023. SILVA, J. J. O. G. Geovana de M. Proposta de modelo de categorização de tweets para identificar o discurso de ódio contra a mulher. **Universidade de Brasília**, 2023.

X 2026 X. **Perguntas frequentes para novos usuários**. 2026. Acesso em: 15 de maio de 2026. Disponível em: <https://help.x.com/pt/resources/new-user-faq>.

X Corp. 2024 X Corp. **Política de conduta odiosa**. 2024. Central de Ajuda do X. Acesso em: 6 maio 2026. Disponível em: <https://help.x.com/pt/rules-and-policies/hateful-conduct-policy>.

Yuan et al. 2023 YUAN, S. et al. Design and visualization of python web scraping based on third-party libraries and selenium tools. **Academic Journal of Computing & Information Science**, Francis Academic Press, v. 6, n. 9, p. 25–31, 2023.

Zanello e Romero 2012 ZANELLO, V.; ROMERO, A. C. **“Vagabundo” ou “vagabunda”?** **Xingamentos e relações de gênero**. 2012. <http://www.labrys.net.br/labrys22/libre/valeskapt.htm>.